

# **REDES NEURAIS ARTIFICIAIS APRENDIZADO PROFUNDO (2)**

**PROFA. ROSELI AP. FRANCELIN ROMERO**

**SCC – ICMC - USP**

# REDES NEURAIS ARTIFICIAIS

- PERCEPTRONS
- 1970 – 2000 – IA  $\leftrightarrow$  SISTEMAS ESPECIALISTAS
- 1970 – 2010 – DESENVOLVIMENTO DA TEORIA DE APRENDIZADO DE MÁQUINA
  - McClelland & PDP Group (1986) – ALGORITMO BACK-PROPAGATION
  - Fukushima's Neocognitron (1989)
  - LeCun's LeNet (1998) – “nova primavera” surgiu

# INÍCIO

## NEW NAVY DEVICE LEARNS BY DOING

Psychologist Shows Embryo  
of Computer Designed to  
Read and Grow Wiser

WASHINGTON, July 7 (UPI)

—The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.

The embryo—the Weather Bureau's \$2,000,000 "Tot" computer—learned to differentiate between right and left after fifty attempts in the Navy's demonstration for newsmen.

The service said it would use this principle to build the first of its Perceptron thinking machines that will be able to read and write. It is expected to be finished in about a year at a cost of \$100,000.

Dr. Frank Rosenblatt, designer of the Perceptron, conducted the demonstration. He said the machine would be the

ings, Perceptron will make mistakes at first, but will grow wiser as it gains experience, he said.

Dr. Rosenblatt, a research psychologist at the Cornell Aeronautical Laboratory, Buffalo, said Perceptrons might be fired to the planets as mechanical space explorers.

### Without Human Controls

The Navy said the perceptron would be the first non-living mechanism "capable of receiving, recognizing and identifying its surroundings without any human training or control."


The "brain" is designed to remember images and information it has perceived itself. Ordinary computers remember only what is fed into them on punch cards or magnetic tape.

Later Perceptrons will be able to recognize people and call out their names and instantly translate speech in one language to speech or writing in another language, it was predicted.


Mr. Rosenblatt said in principle it would be possible to build brains that could reproduce themselves on an assembly

# BACK-PROPAGATION (1986)

## REDES MULTI-CAMADAS (MLP)



# NEOCOGNITRON (FUKUSHIMA – 1989)



# LENET – LeCun (1998)

 10 OUTPUT

 12@4x4 H4

 12@8x8 H3

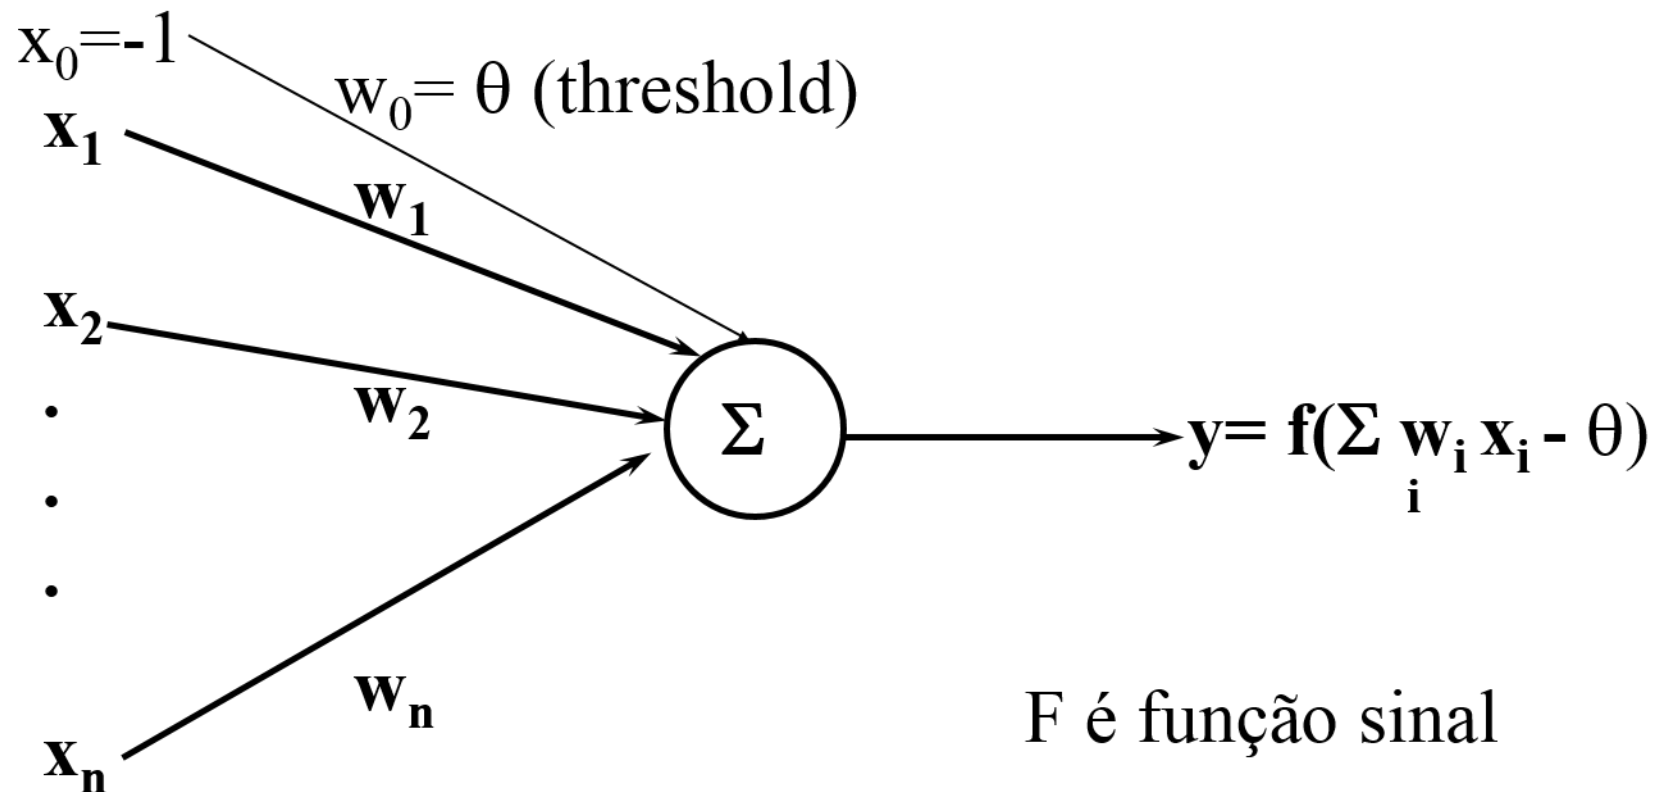
 4@12x12 H2

 4@24x24 H1

 28x28 INPUT




# Modelo de um neurônio simples



F é função sinal



# FUNÇÕES DE ATIVAÇÃO



**Sigmoid**

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



**tanh**

$$\tanh(x)$$



**ReLU**

$$\max(0, x)$$



**Leaky ReLU**

$$\max(0, 1x, x)$$




**Maxout**

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

**ELU**

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$





# O que é Aprendizado?

“Aprendizado é um processo pelo qual os parâmetros livres de uma rede neural são adaptados através de um processo contínuo de estímulos pelo ambiente no qual a rede está incorporada”.

W e B = ?

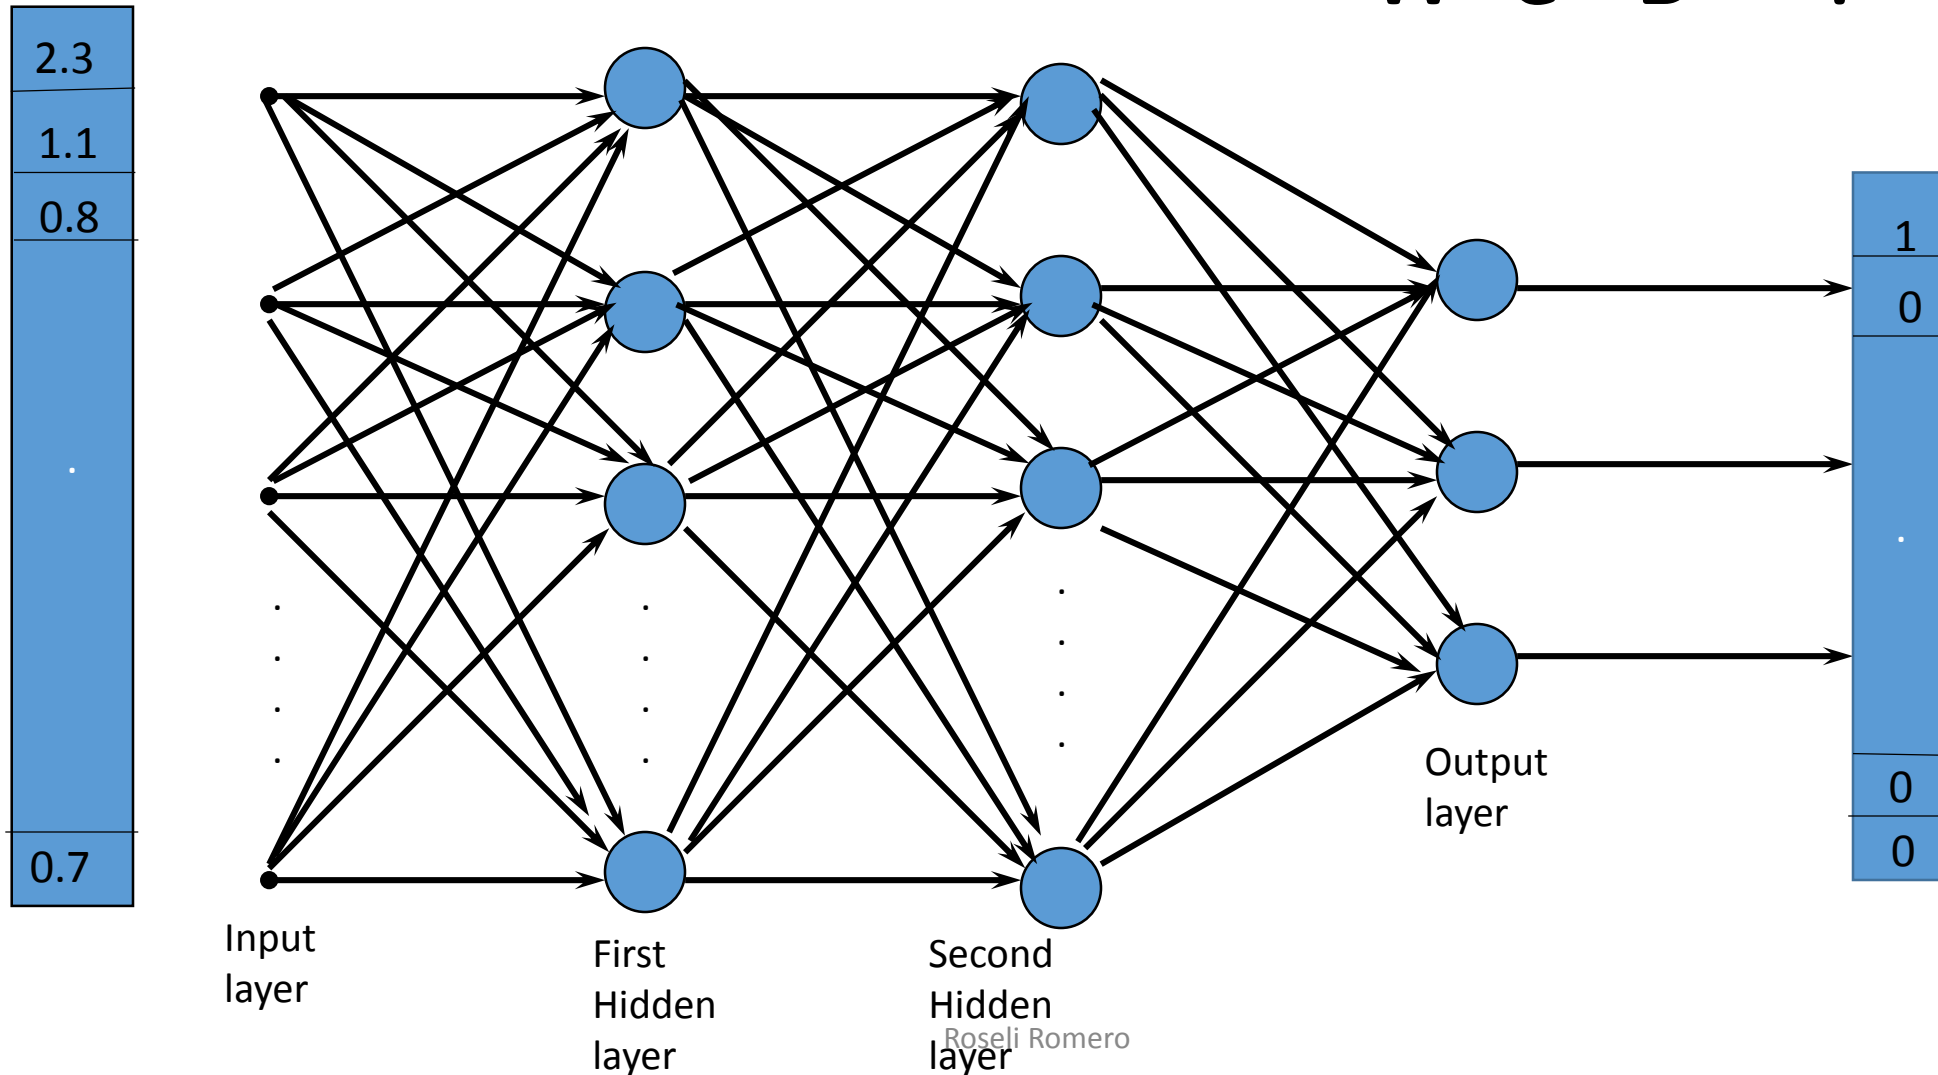
# Aprendizado em RNA

Durante o processo de aprendizado:

- 1- A rede neural é estimulada por um ambiente.
- 2 - A rede muda com o resultado deste estímulo
- 3 - A rede responde de um novo modo ao ambiente, em função das mudanças que ocorreram na sua estrutura interna.

# Modelo de Rede Neural com Múltiplas Camadas - MLP

$W$  e  $B = ?$



# II - Algoritmo BackPropagation

## OBJETIVO

- Encontrar um conjunto de pesos  $\{W_j\}, \{B_j\}$ , para

**MINIMIZAR**  $\sum_i (y_i - \text{Out}(\underline{x}_i))^2$

pelo método do “gradiente descendente”.

**OBS:** Convergência para um MINIMO global não é garantida.

**Na prática:** não é problema!!!

## II - Algoritmo Back-Propagation

$$\Delta w_{jk} = -\eta \delta_j^p out_k^p$$

- Se o neurônio está na camada de saída

$$\delta_{pj} = (y_j^p - out_j^p) f'(net_j^p)$$

$$net_j^p = \sum_k w_{jk} out_k^p$$

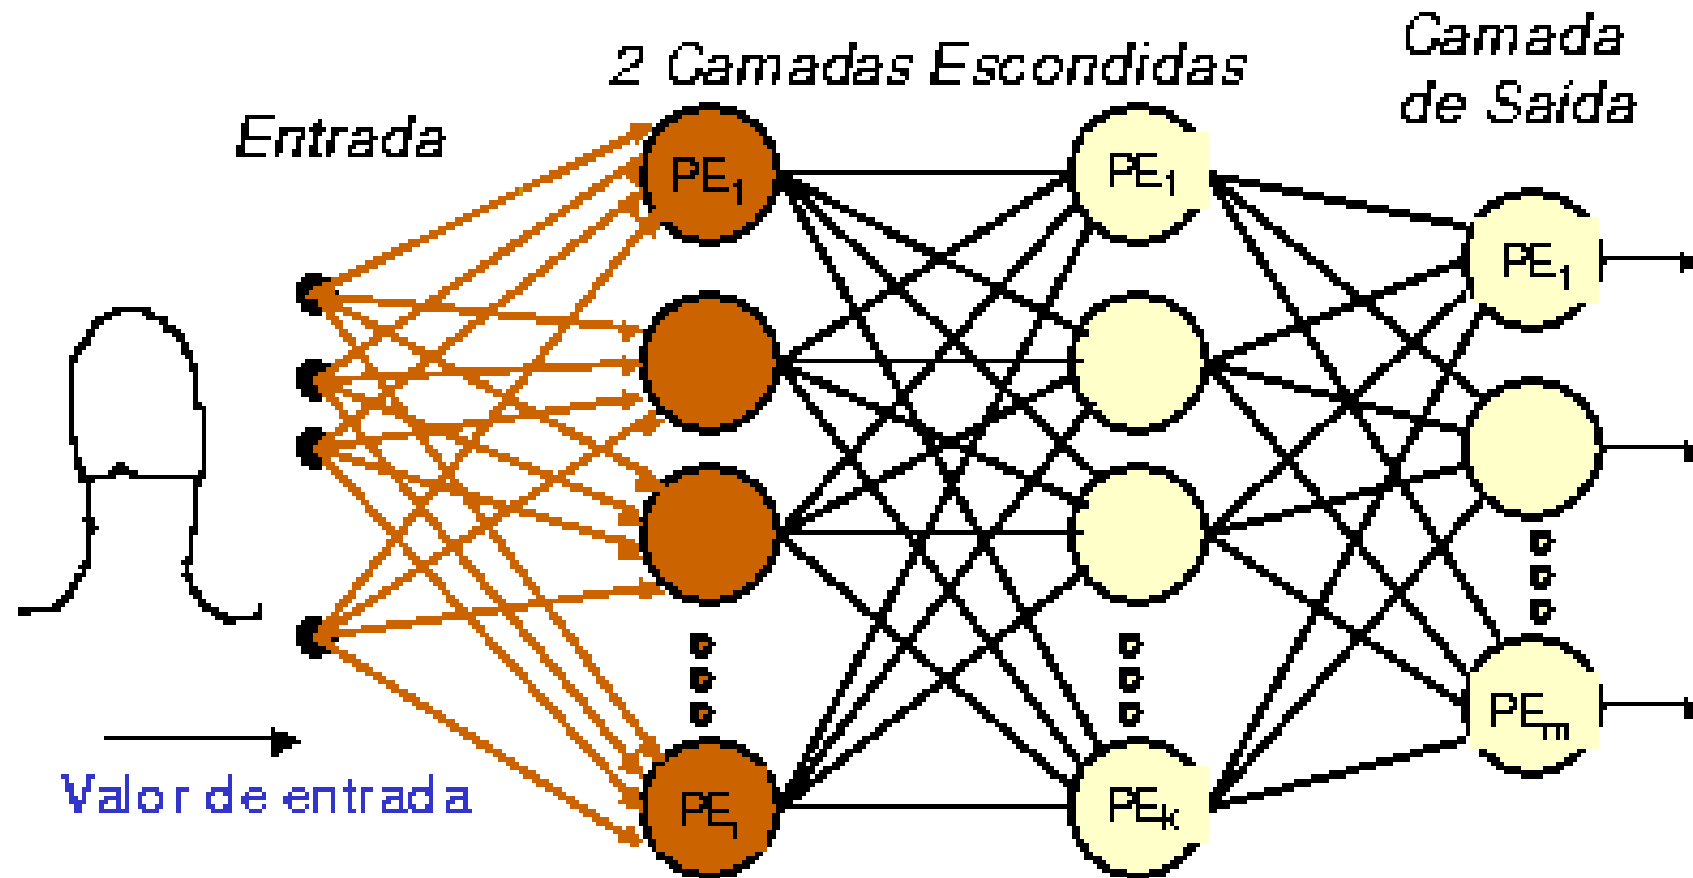
- Se o neurônio está na camada oculta

$$\delta_{pj} = f'(net_j^p) \sum_k \delta_k^p w_{kj}$$

# PROCESSO DE APRENDIZADO

## Fase 1: Feed-Forward

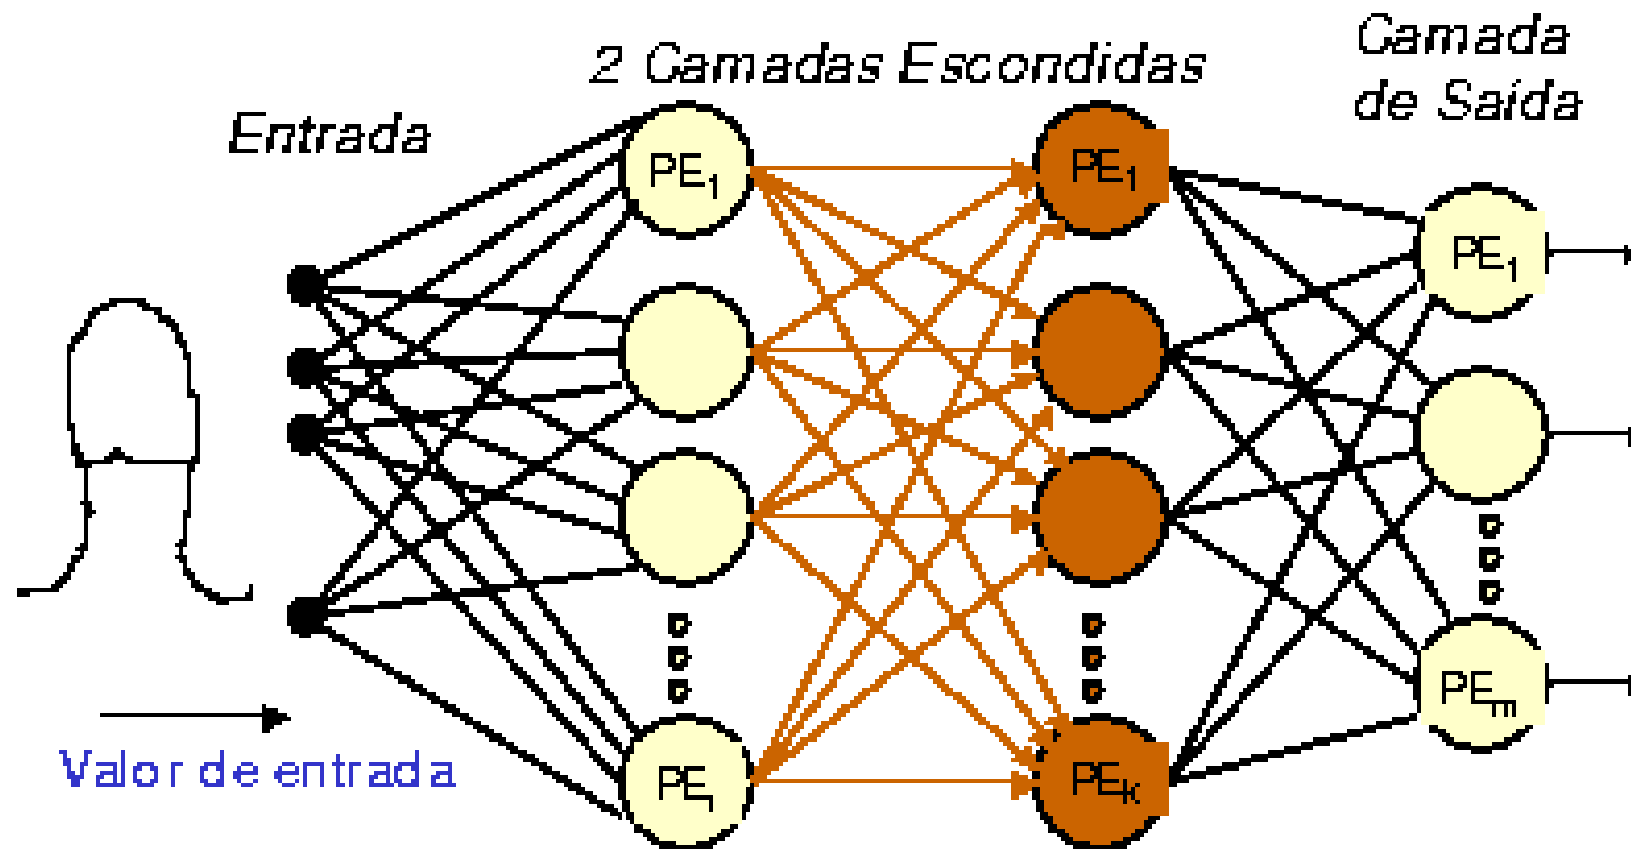
Fluxo de Dados →



# PROCESSO DE APRENDIZADO

## Fase 1: Feed-Forward

Fluxo de Dados

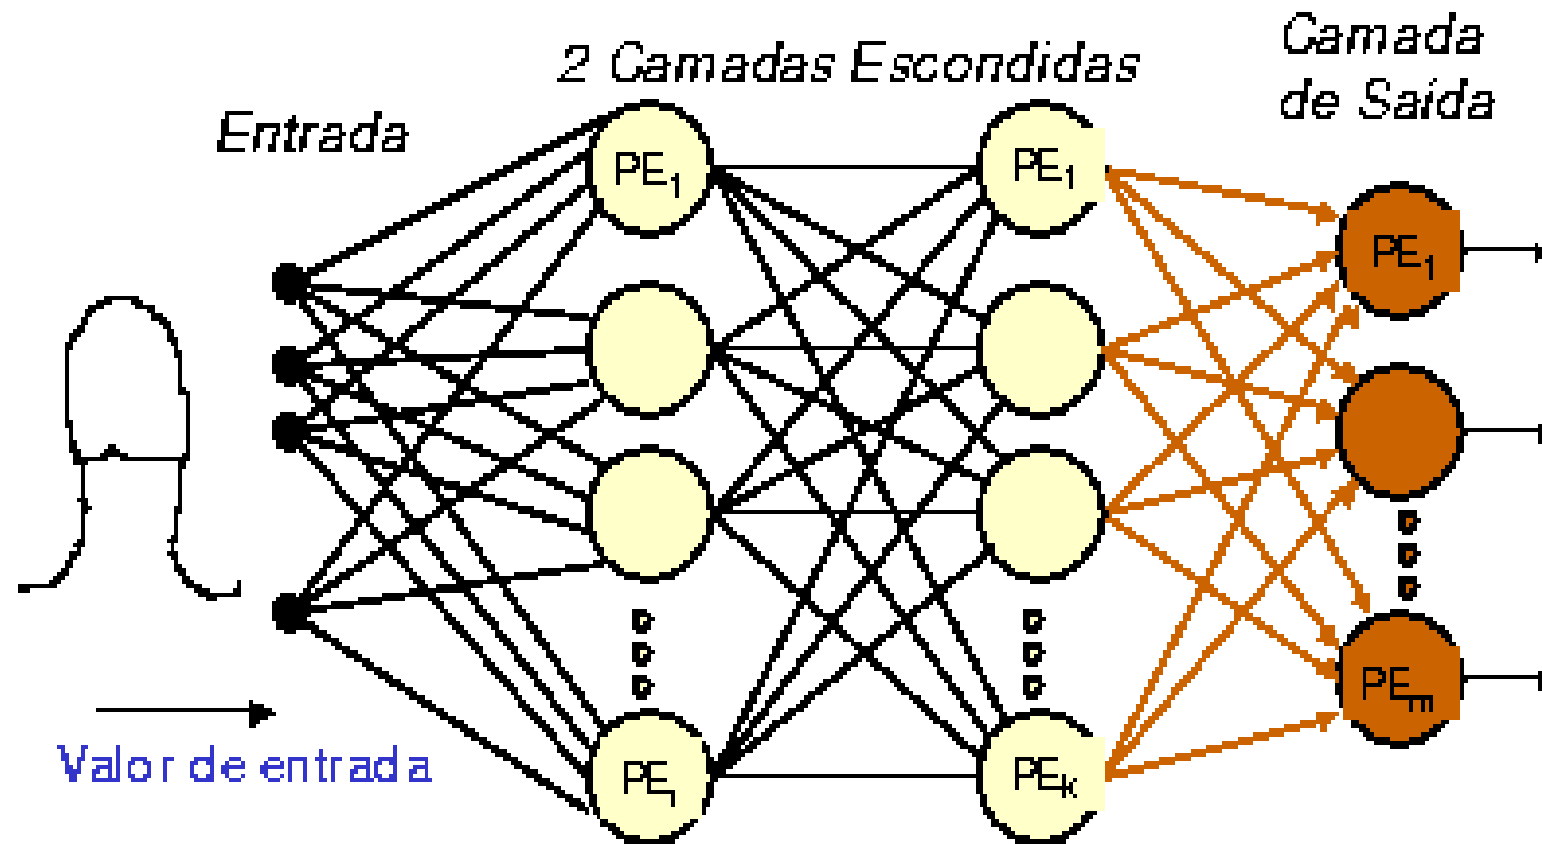




# PROCESSO DE APRENDIZADO

## Fase 1: Feed-Forward

Fluxo de Dados




# PROCESSO DE APRENDIZADO

## Fase 2: Feed-Backward

Cálculo do erro da camada de saída

Fluxo de Erros

Valor  
alvo




# PROCESSO DE APRENDIZADO

## Fase 2: Feed-Backward

Fluxo de Erros




Atualização dos pesos da camada de saída



# PROCESSO DE APRENDIZADO

Fase 2: Feed-Backward      Fluxo de Erros  
Cálculo do erro da 2ª camada escondida



$$e_k = (\sum e_m \cdot w_{km}) \cdot F'(net)$$


# PROCESSO DE APRENDIZADO

## Fase 2: Feed-Backward

Fluxo de Erros



Atualização dos pesos da 2ª camada escondida




# PROCESSO DE APRENDIZADO

## Fase 2: Feed-Backward

Fluxo de Erros



Cálculo do erro da 1ª camada escondida



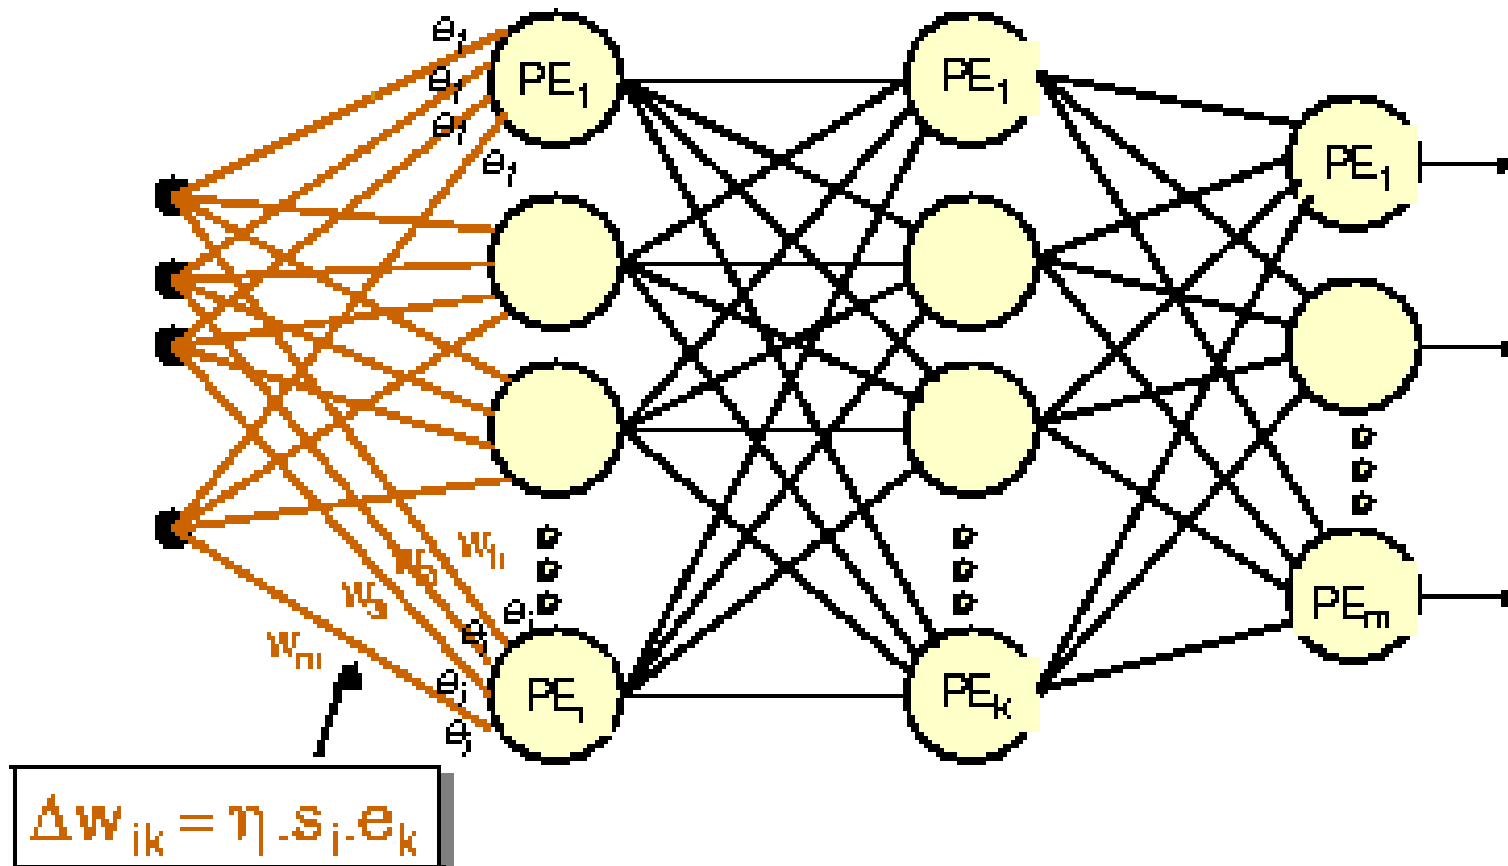
$$e_i = (\sum e_k w_{ik}) \cdot F'(\text{net})$$

## PROCESSO DE APRENDIZADO

## Fase 2: Feed-Backward

## Fluxo de Erros

### Atualização dos pesos da 1ª camada escondida



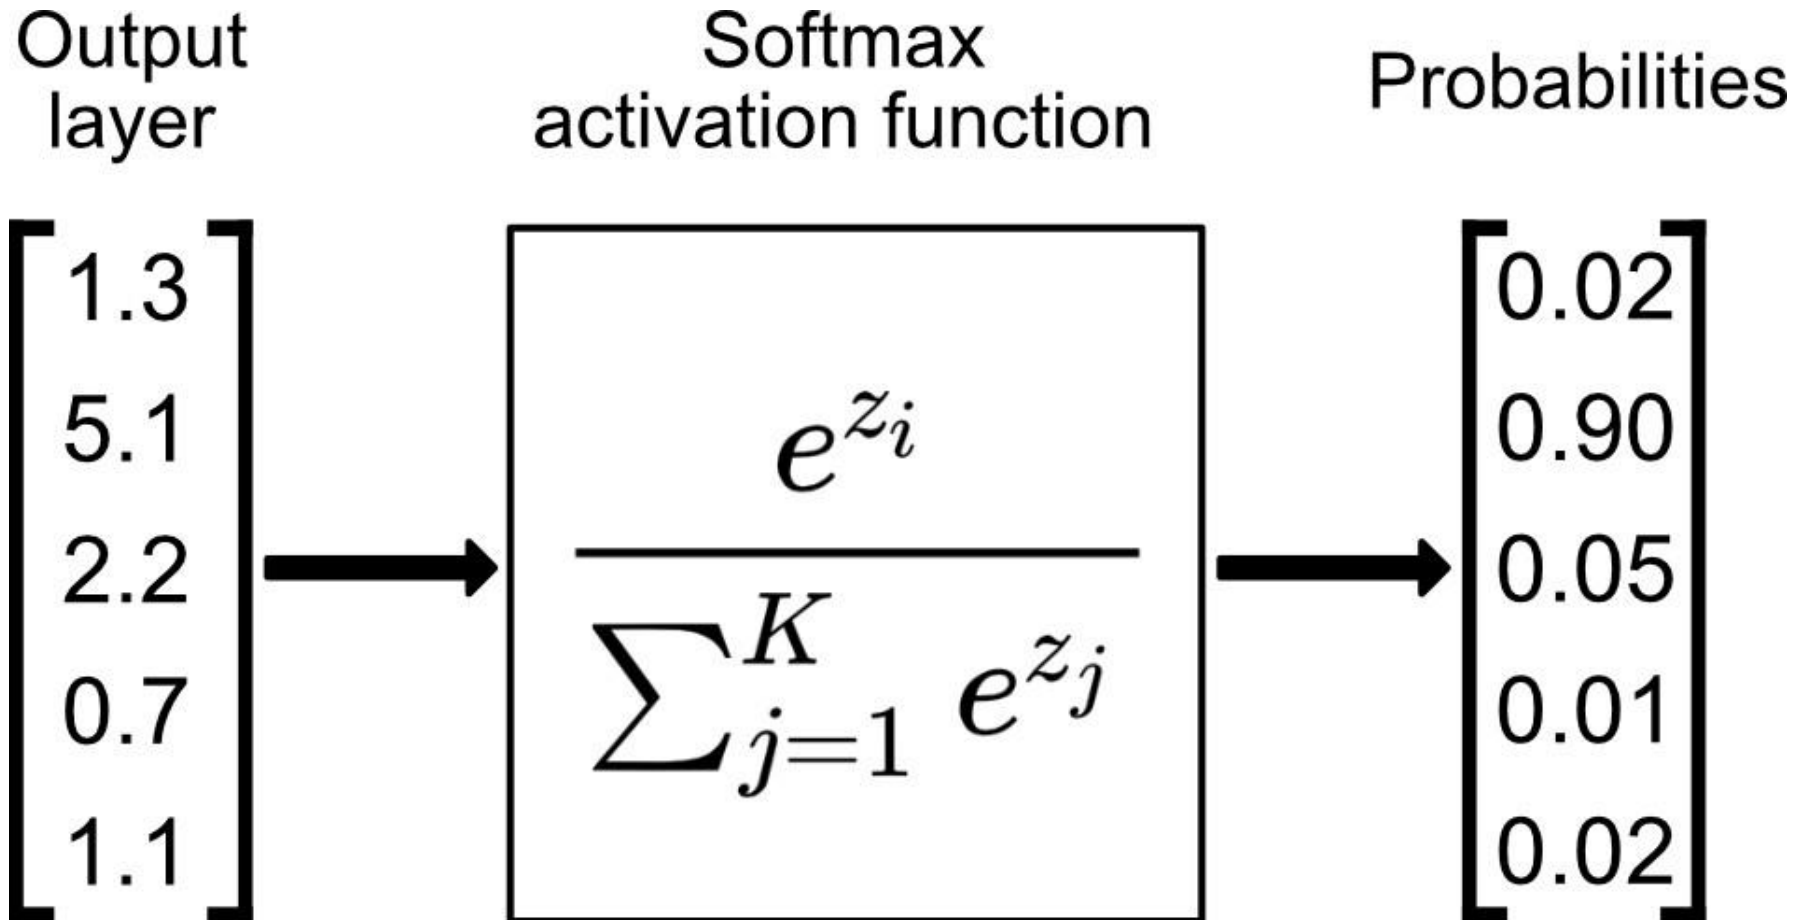


**MLP podem ser  
usadas:**

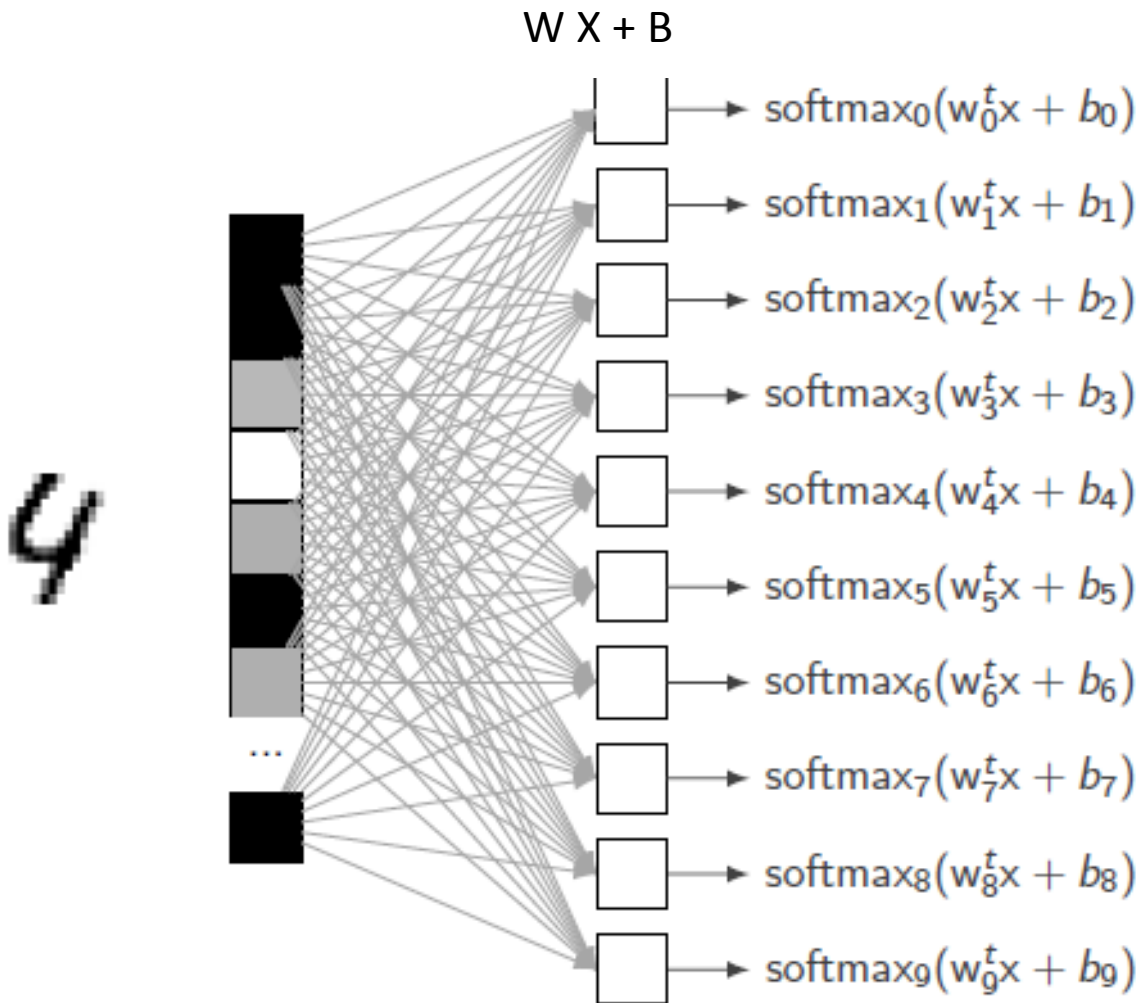
- CLASSIFICAÇÃO**
- REGRESSÃO**

# FUNÇÃO SOFTMAX

Permite mais do que 2 classes de saída  
Padroniza vetor de saída de forma a somar 1  
Interpretação: valores são probabilidades  
Saída: distr. de prob. das classes

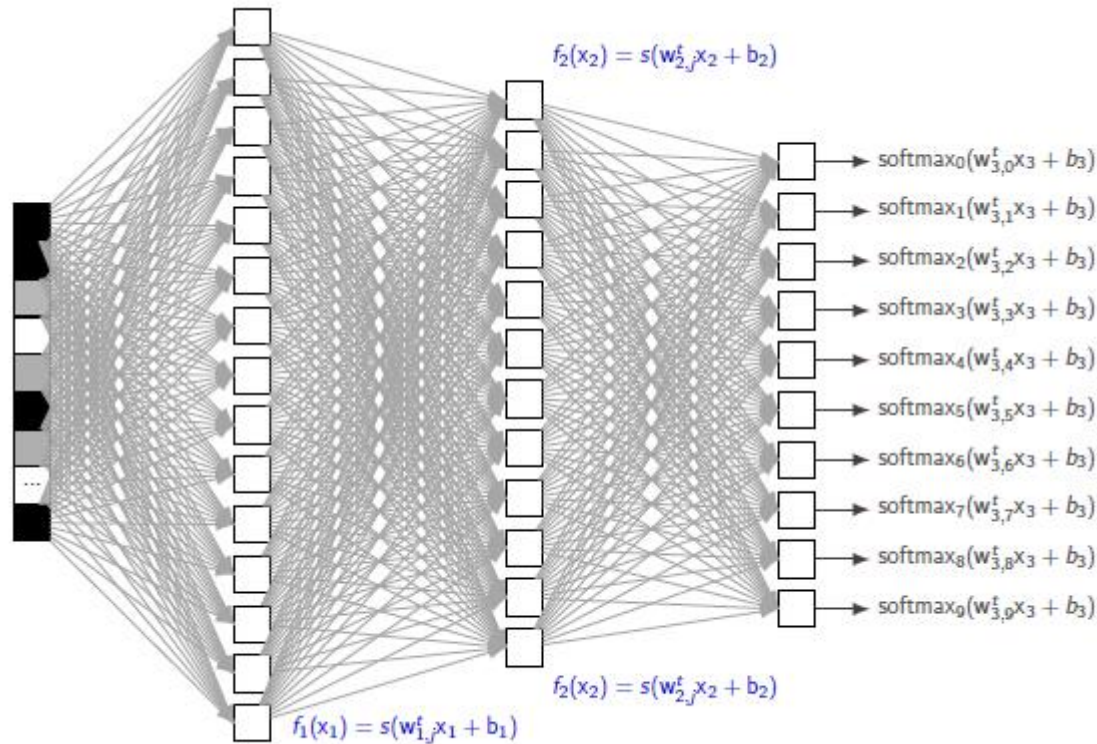


# Questões importantes sobre MLP



1. Valores de entrada (atributos) são considerados independentes
2. Não são aproveitadas relações locais entre os dados

# Questões importantes sobre MLP




3. Número de parâmetros crescente impacta restrições de memória e processamento

=> Exemplo: entrada imagem de 28 x 28 = 784 pixels

Uma camada com 100 neurônios tem...

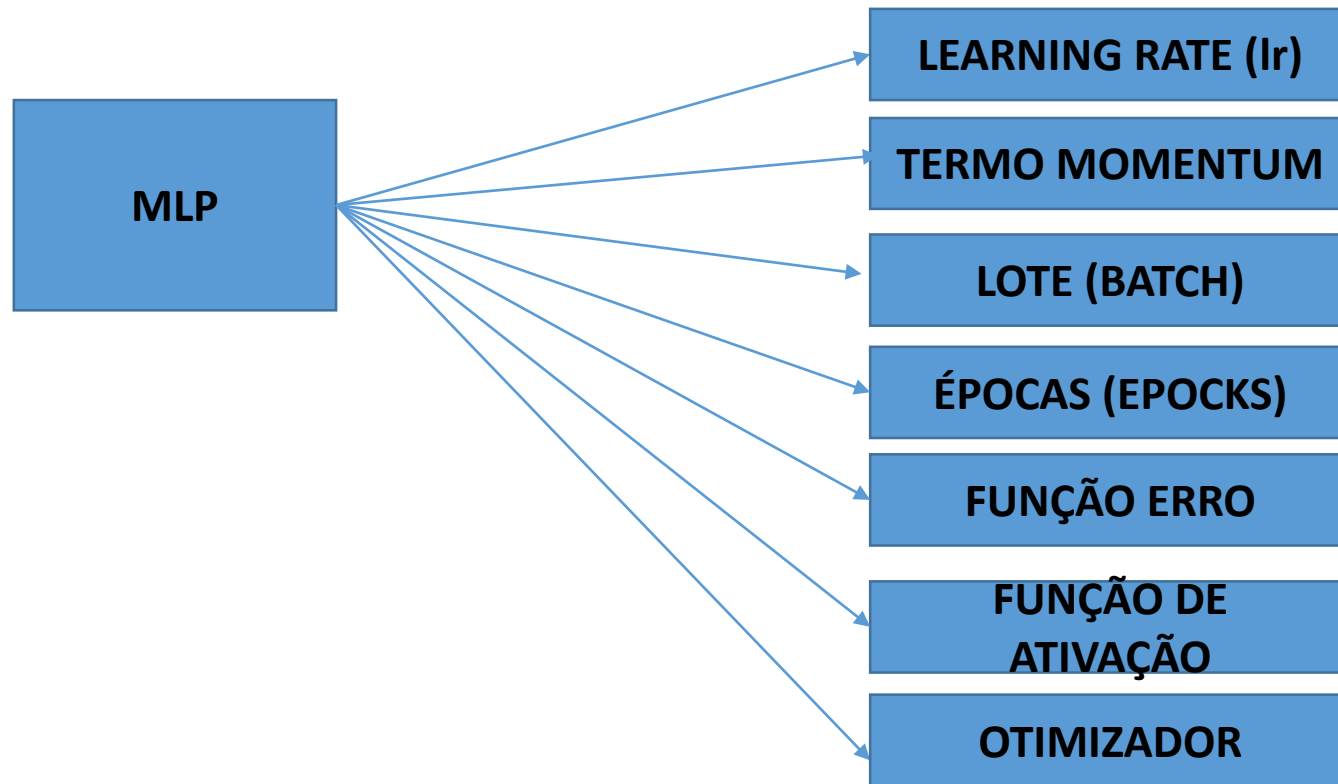
**78400 + 100 = 78500** parâmetros a serem aprendidos e mantidos na memória durante o treinamento

# MLP e RECONHECIMENTO



# **QUESTÕES DE IMPLEMENTAÇÃO DO MODELO MLP**


# IMPLEMENTAÇÃO DO MODELO MLP





# IMPLEMENTAÇÃO DO MODELO MLP

## LEARNING RATE – PARÂMETRO DE APRENDIZADO




$$\Delta w_{jk} = -\eta \delta_j^p out_k^p$$

$\eta$  - parâmetro de  
aprendizado  
 $0 < \eta < 1$

# IMPLEMENTAÇÃO DO MODELO MLP

## TERMO MOMENTUM

$$\Delta w_{ji}(n) = \eta \delta_j(n) y_i(n) + \alpha \Delta w_{ji}(n - 1)$$



$\alpha$  - parâmetro de  
aprendizado  
 $0 < \alpha < 1$

# IMPLEMENTAÇÃO DO MODELO MLP

**LOTE – SUBCONJUNTO A SER TREINADO**

**ÉPOCAS (early stopping) – TREINAMENTO  
COMPLETO DO CONJUNTO DE DADOS**


**FUNÇÃO ERRO – MSE**

**FUNÇÃO DE ATIVAÇÃO – SIGMOID OU RELU**

**OTIMIZADOR - SGD**

# APRENDIZADO PROFUNDO x MLP

- EXEMPLO: 10 classes e batch size 32 e 784 características (pixels) por imagem



MNIST

TREINAMENTO: 50.000

TESTE: 10.000

BATCH = 32

$$\begin{bmatrix} x_{0,0} & x_{0,1} & x_{0,2} & \dots & x_{0,783} \\ x_{1,0} & x_{1,1} & x_{1,2} & \dots & x_{1,783} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{31,0} & x_{31,1} & x_{31,2} & \dots & x_{31,783} \end{bmatrix} \begin{bmatrix} w_{0,0} & w_{0,1} & \dots & w_{0,9} \\ w_{1,0} & w_{1,1} & \dots & w_{1,9} \\ w_{2,0} & w_{2,1} & \dots & w_{2,9} \\ \vdots & \vdots & \ddots & \vdots \\ w_{783,0} & w_{783,1} & \dots & w_{783,9} \end{bmatrix} + [b_0 \ b_1 \ b_2 \ \dots \ b_9]$$

$$Y = \text{softmax}(X \cdot W + b)$$

$$Y = \begin{bmatrix} y_{0,0} & y_{0,1} & y_{0,2} & \dots & y_{0,9} \\ y_{1,0} & y_{1,1} & y_{1,2} & \dots & y_{1,9} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ y_{31,0} & y_{31,1} & y_{31,2} & \dots & y_{31,9} \end{bmatrix}$$

# **EXEMPLO 1**

**MLP**

**USO DO KERAS**

# **REDES NEURAIS PROFUNDAS**




# 1º. MOTIVO

- IMAGENET – aproximadamente 1,4 milhões de imagens (2009)
- 1000 classes no total – categorizar essas imagens




## 2º. MOTIVO

- CPU X GPU – Alta densidade de processamento
  - controle simples
  - cache pequeno
  - alta tolerância a latência




**CPU**



**GPU**

# 3º. MOTIVO

## Não-linearidade: Funções de Ativação



# 4º. MOTIVO

- REVISITAÇÃO DO MODELO LE CUN

 10 OUTPUT

 12@4x4 H4

SUB-  
AMOSTRAGEM

 12@8x8 H3

CONVOLUÇÃO

 4@12x12 H2

SUB-  
AMOSTRAGEM

 4@24x24 H1


CONVOLUÇÃO

 28x28 INPUT


# PRINCIPAIS MODELOS DE REDES PROFUNDAS

ALEX NET (9)      INCEPTION (22)      VGGNET (16/19)      RESNET(34-1000)

ImageNet Large Scale Visual Recognition Challenge (ILSVRC) winners



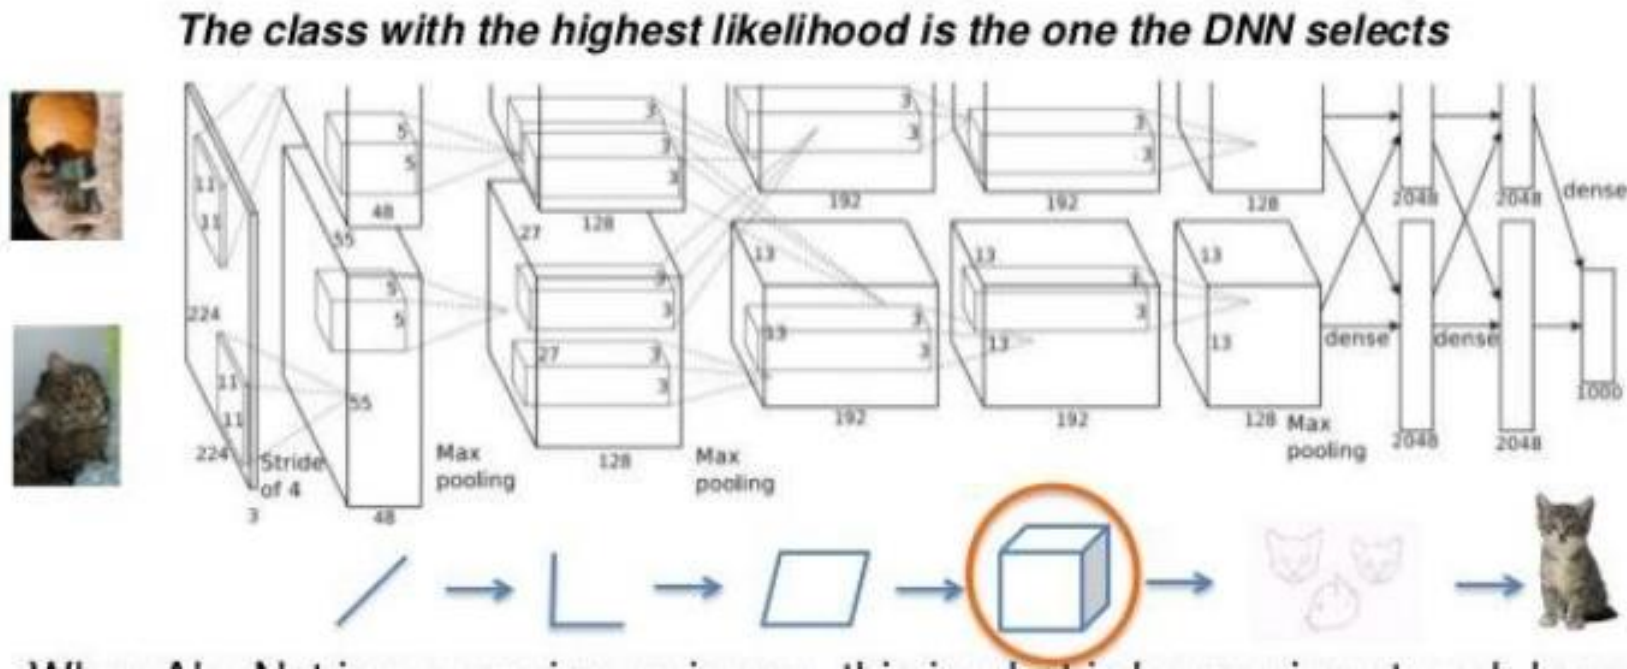
# REDES NEURAIS CONVOLUCIONAIS






# ALEX NET (2012)

9 CAM.



# INCEPTION / GOOGLNET (2014)


22 CAM.





# VGGNET (2014)


16 CAM.




© Roseli Romero

# RESNET (2015)

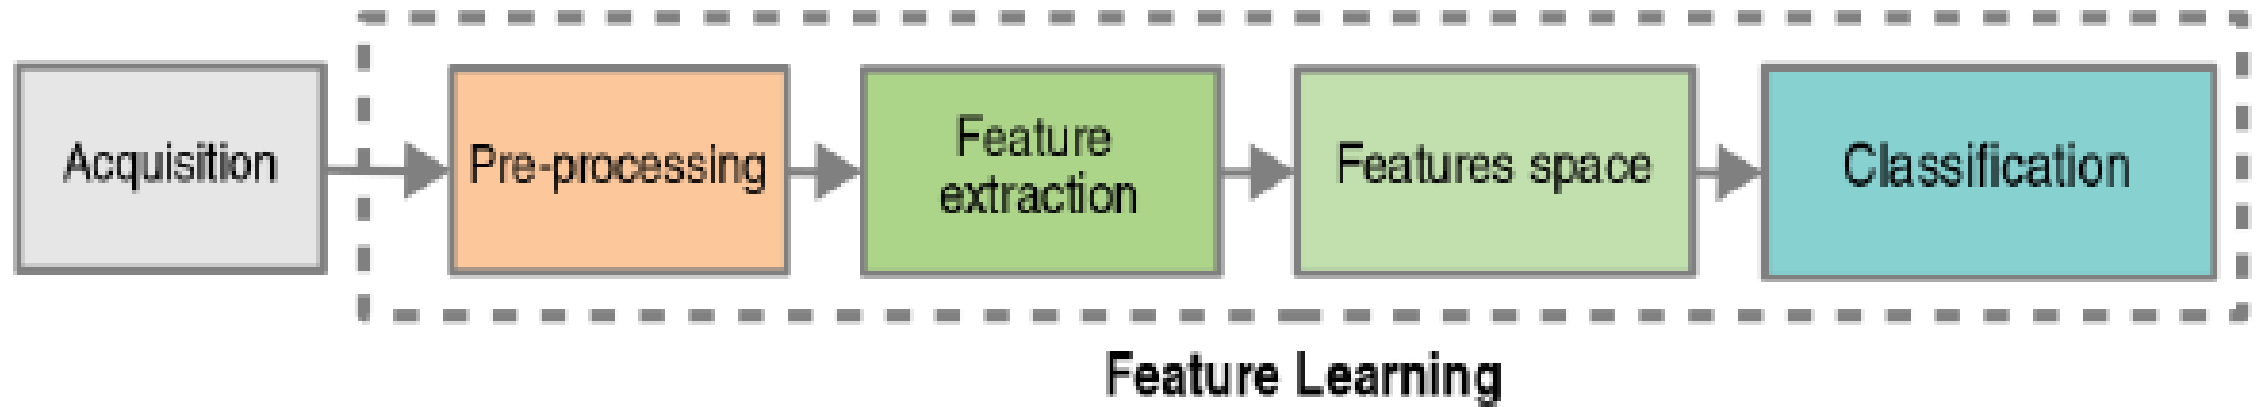
34 A 1000 CAM.



# DEEP LEARNING



$$\mathbf{x} \in \mathbb{R}^m$$



Novo Pipeline para Tratamento de Imagens

# NOVA TERMINOLOGIA

- CAMADA CONVOLUCIONAL
- MAPAS DE ATIVAÇÃO (ACTIVATION TEXTURE MAPS)
- CAMADA DENSA (DENSE OR FULLY CONNECTED)
- SUBAMOSTRAGEM ( POOLING)

# CONVOLUÇÃO

- OPERADOR QUE VISA REALIZAR UMA COMBINAÇÃO LINEAR DE VALORES LOCAIS DA ENTRADA
- CENTRADO EM UMA POSIÇÃO, isto é,  $(x,y)$ , gera como saída um único valor de saída
- CONVOLUÇÃO 1D



# APRENDIZADO PROFUNDO

3	0	1	2	7	4
1	5	8	9	3	1
2	7	2	5	1	3
0	1	3	1	7	8
4	2	1	6	2	8
2	4	5	2	3	9

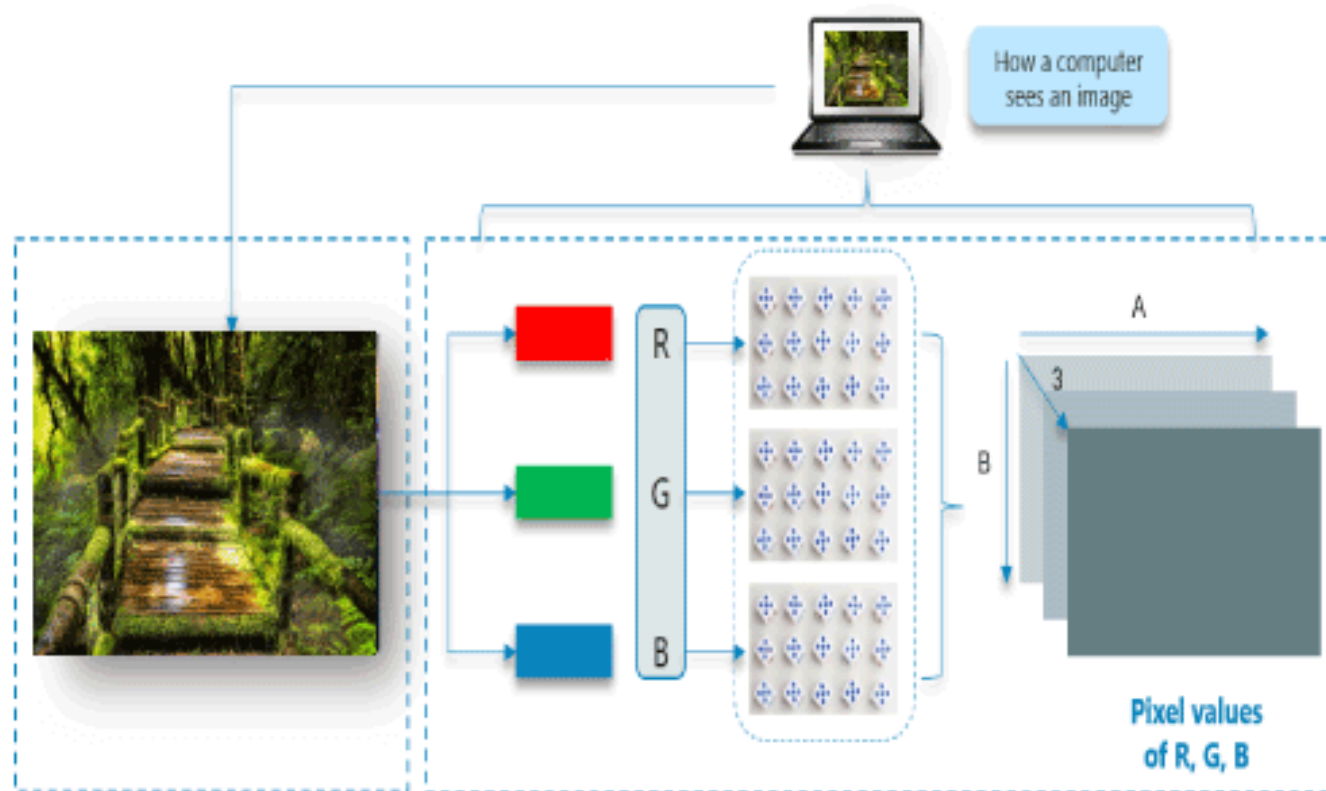
\*

1	0	-1
1	0	-1
1	0	-1



-5	-4	0	8

# APRENDIZADO PROFUNDO



# Convolução 3D

0	0	0	0	0	0	...
0	156	155	156	158	158	...
0	153	154	157	159	159	...
0	149	151	155	158	159	...
0	146	146	149	153	158	...
0	145	143	143	148	158	...
...	...	...	...	...	...	...

Input Channel #1 (Red)

0	0	0	0	0	0	...
0	167	166	167	169	169	...
0	164	165	168	170	170	...
0	160	162	166	169	170	...
0	156	156	159	163	168	...
0	155	153	153	158	168	...
...	...	...	...	...	...	...

Input Channel #2 (Green)

0	0	0	0	0	0	...
0	163	162	163	165	165	...
0	160	161	164	166	166	...
0	156	158	162	165	166	...
0	155	155	158	162	167	...
0	154	152	152	157	167	...
...	...	...	...	...	...	...

Input Channel #3 (Blue)

-1	-1	1
0	1	-1
0	1	1

Kernel Channel #1



308

+

1	0	0
1	-1	-1
1	0	-1

Kernel Channel #2



-498

+

0	1	1
0	1	0
1	-1	1

Kernel Channel #3



164

+ 1 = -25




Bias = 1

Output

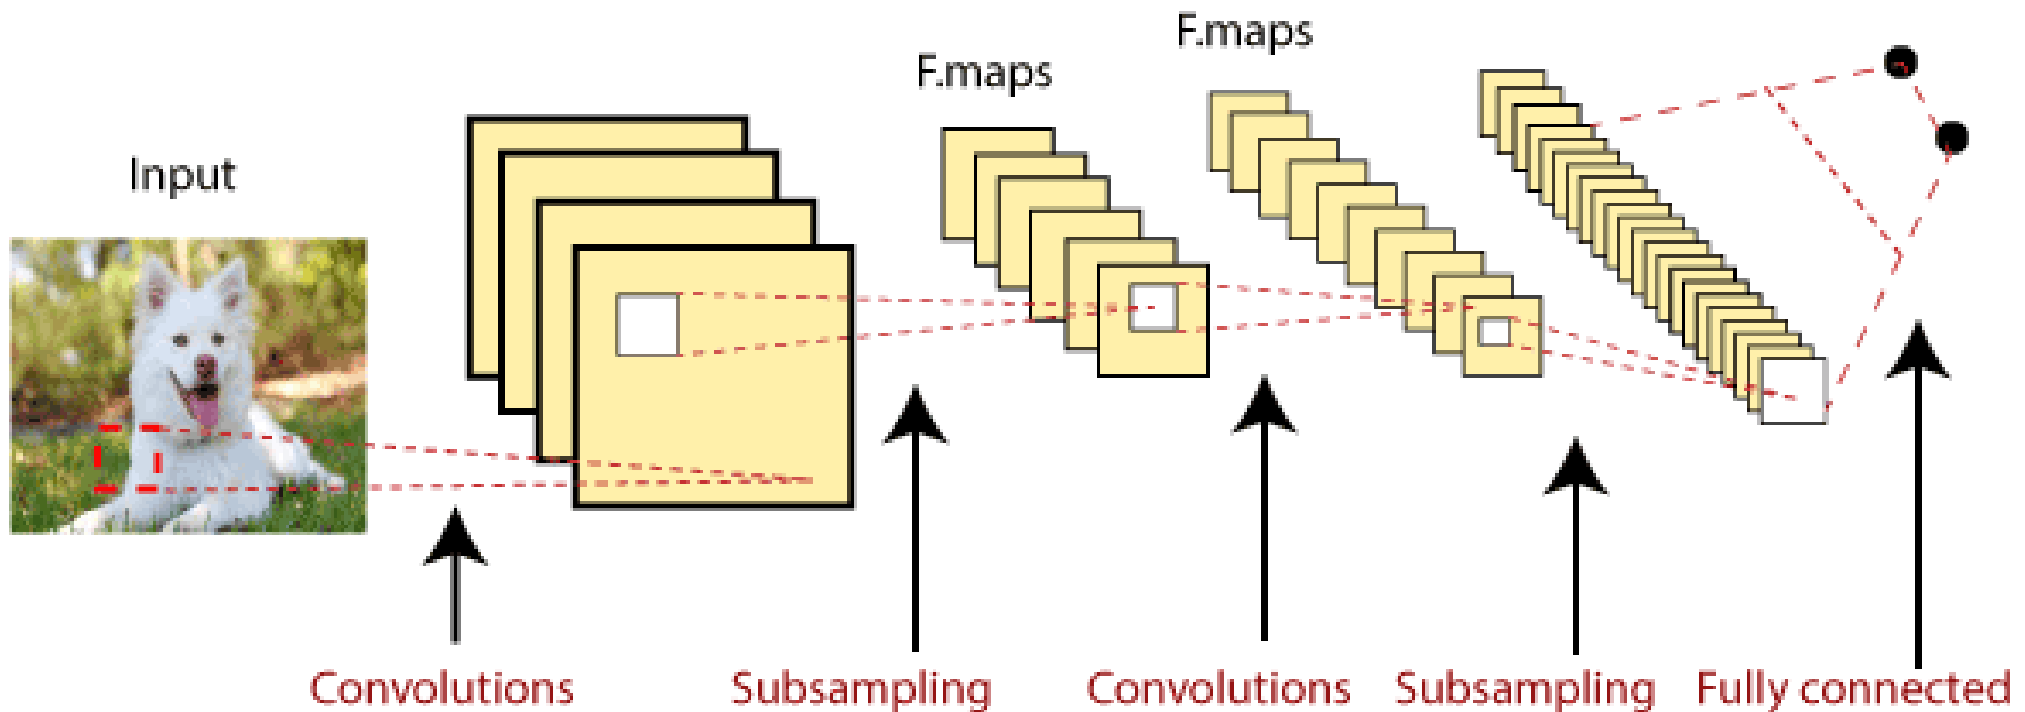
-25				...
				...
				...
				...
...	...	...	...	...



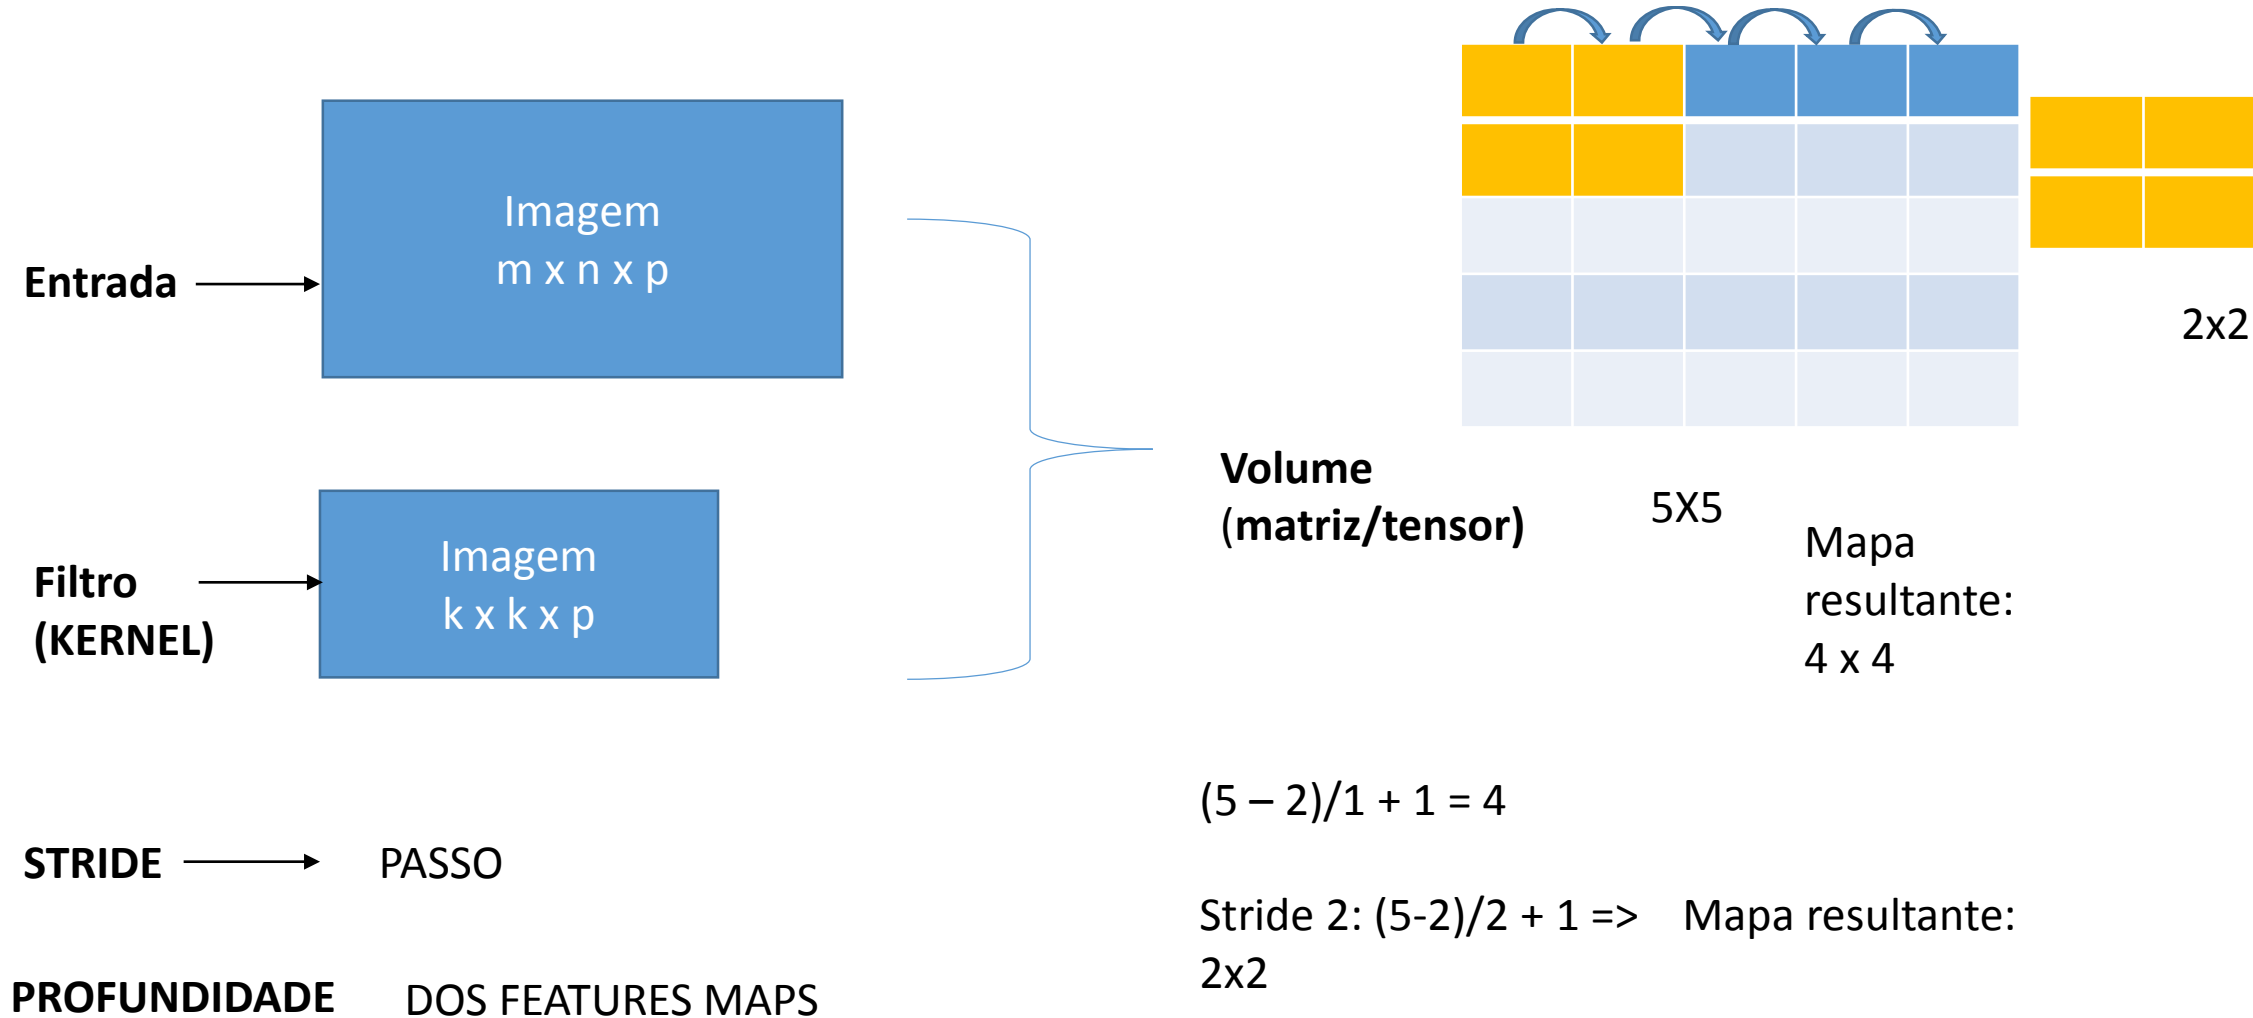
# CONVOLUÇÃO 3D



# APRENDIZADO PROFUNDO



# TAMANHO DOS FEATURES MAPS



# NÚMERO DE PARÂMETROS

$$[(K \times K \times P) + 1] \times D$$


Entrada: 32 x 32 x 3      e 3 Feature Maps

CONV1: K=5   D = 8      #param\_1:  $[(5 \times 5 \times 3) + 1] \times 8 = 608$

CONV2: K=3   D = 16      #param\_2:  $[(3 \times 3 \times 8) + 1] \times 16 = 1168$

CONV3: K=1   D = 32      #param\_3:  $[(1 \times 1 \times 16) + 1] \times 32 = 544$

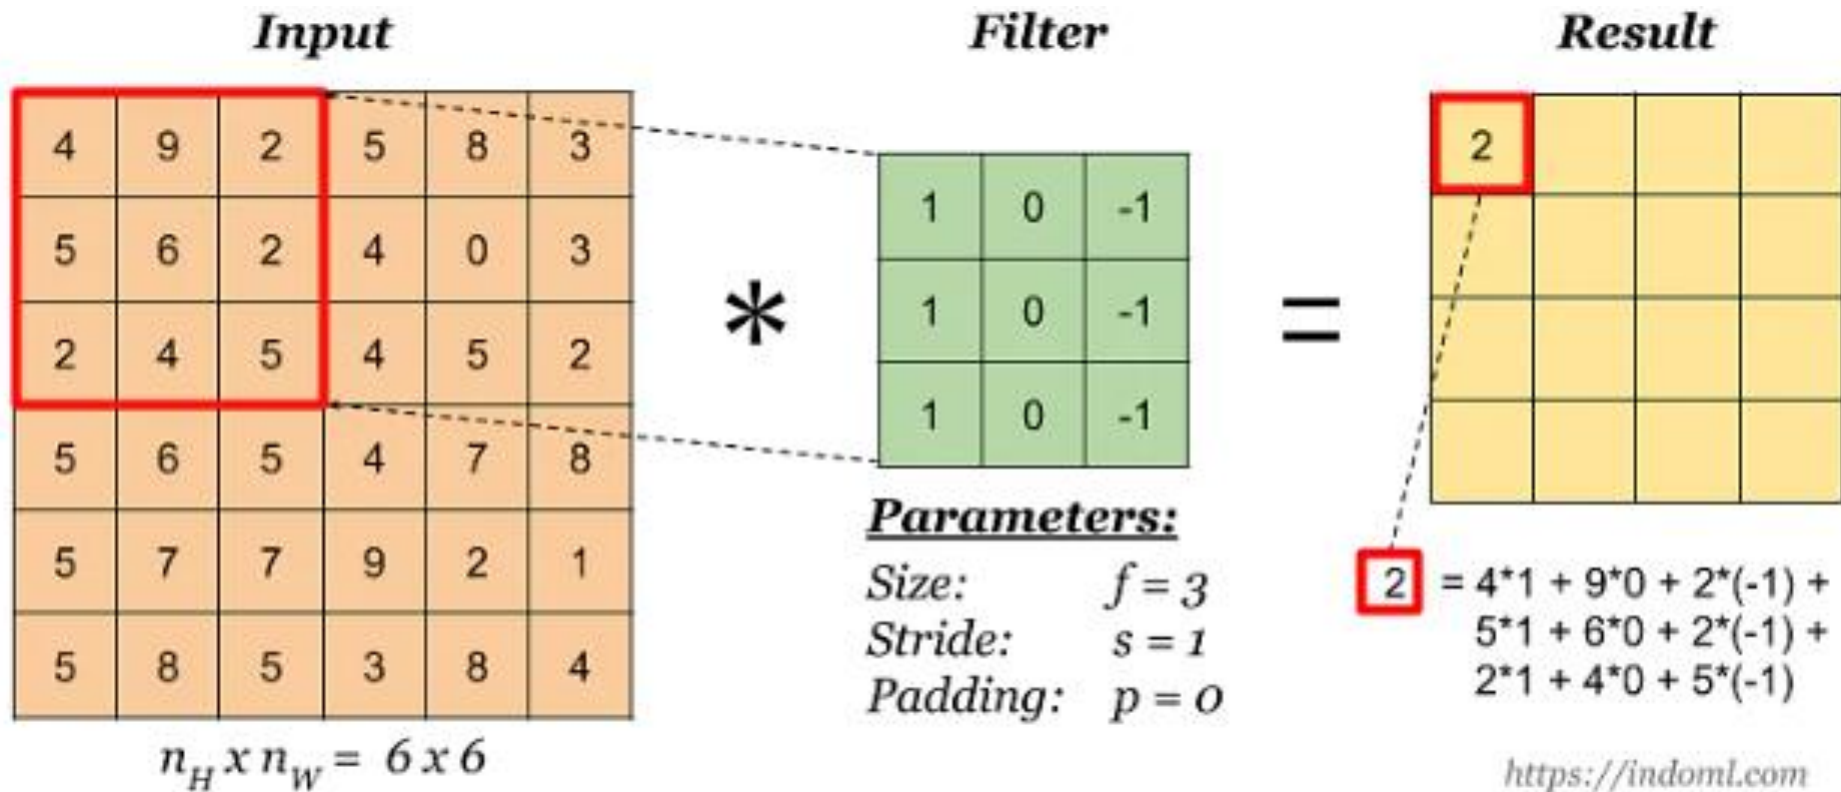
# PADDING



**Zero-padding:** para compensar a impossibilidade de computar todos os valores

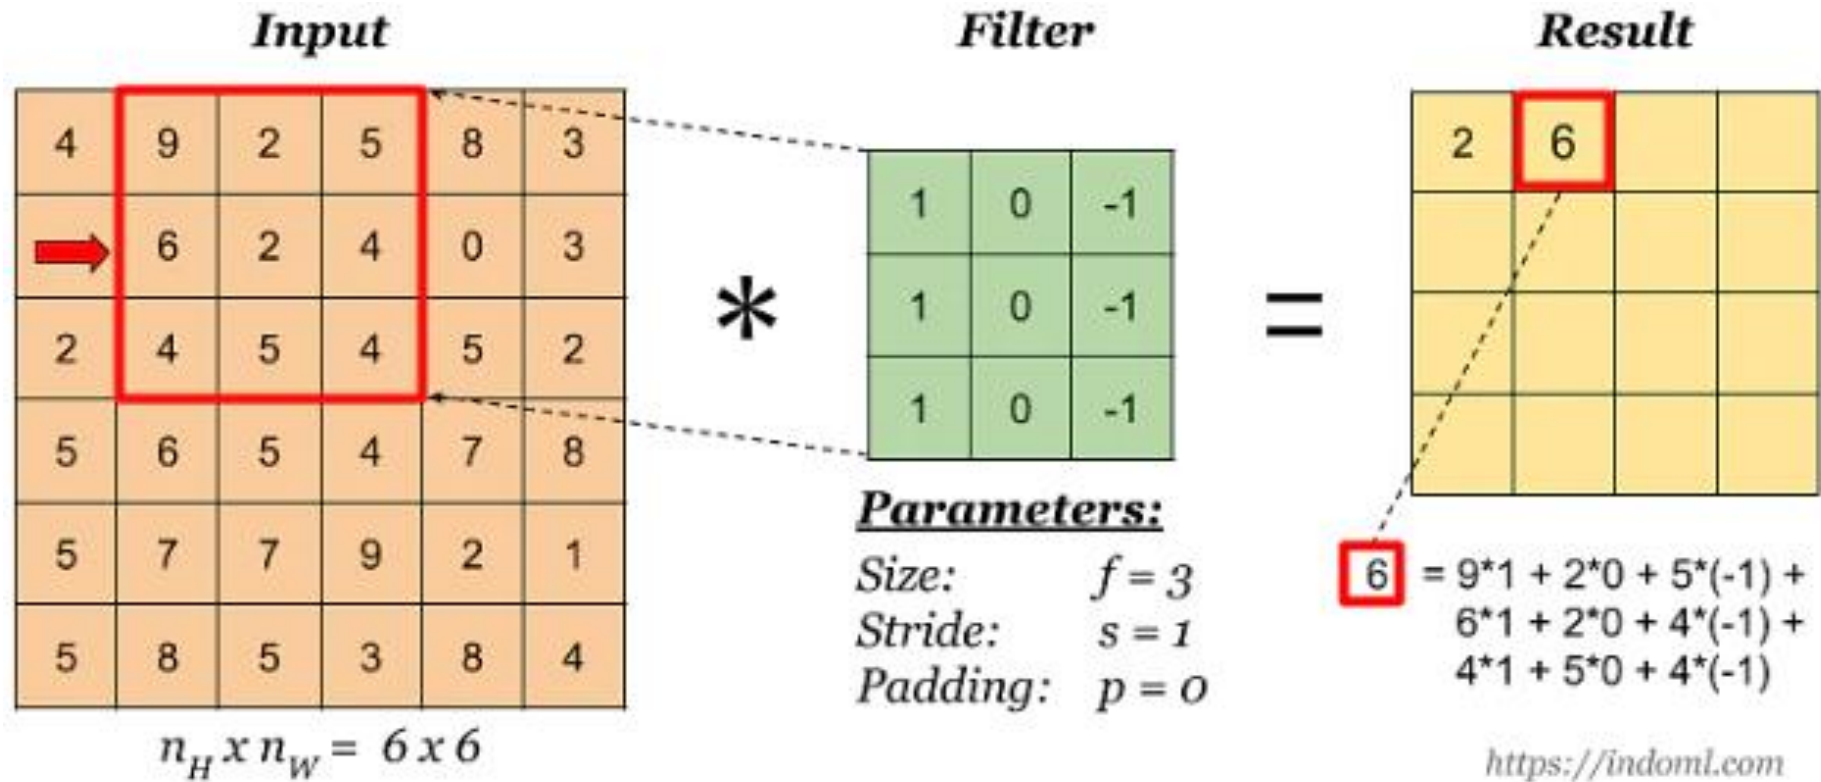
Amplia-se a entrada de forma que o volume de saída seja igual ao da entrada

# CONVOLUÇÃO 2D



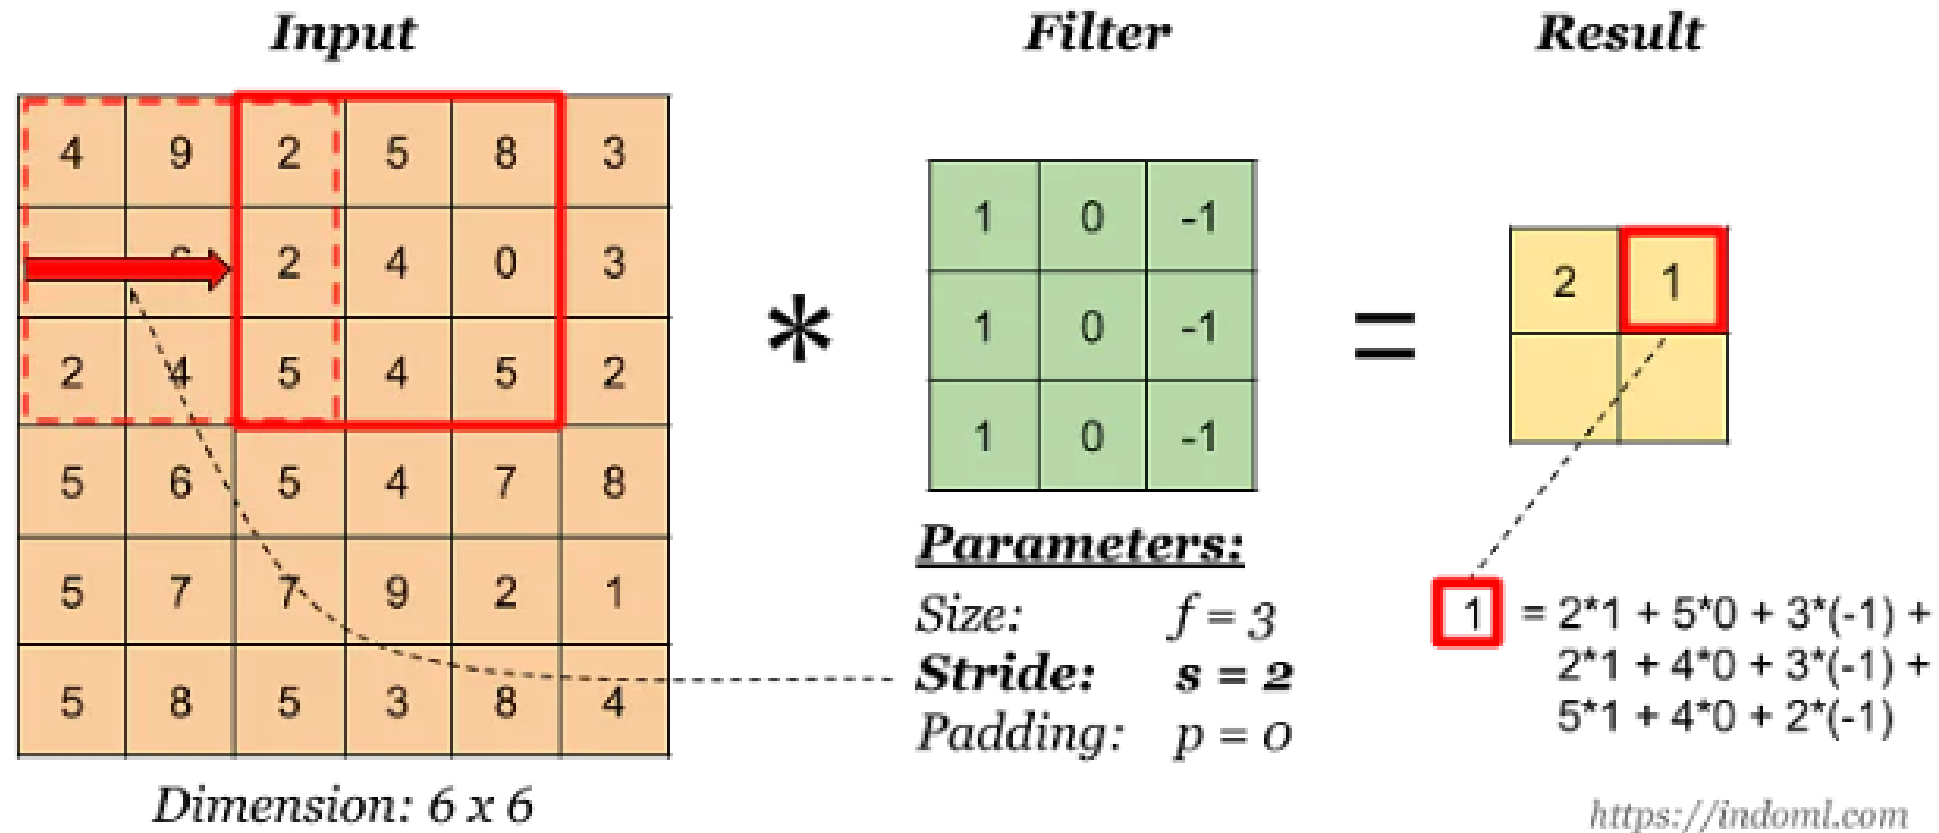
Source: indoml.com

# CONVOLUÇÃO 2D



Source: indoml.com




# CONVOLUÇÃO 2D




Source: [indoml.com](https://indoml.com)



# CONVOLUÇÃO 3D

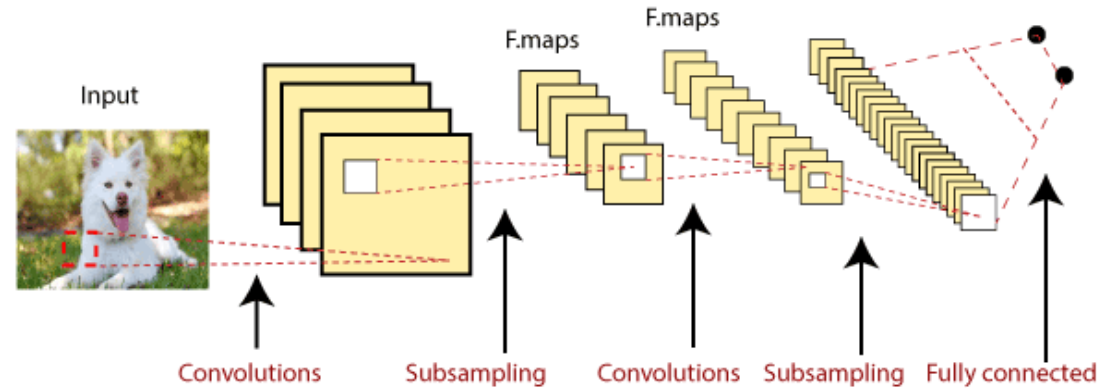


# CONVOLUÇÃO 3D



# CONVOLUÇÃO 3D

- ENTRADA (mxn xp)  
(32 x 32 x 3)



FILTRO (kxk xp)  
(5x5x3)

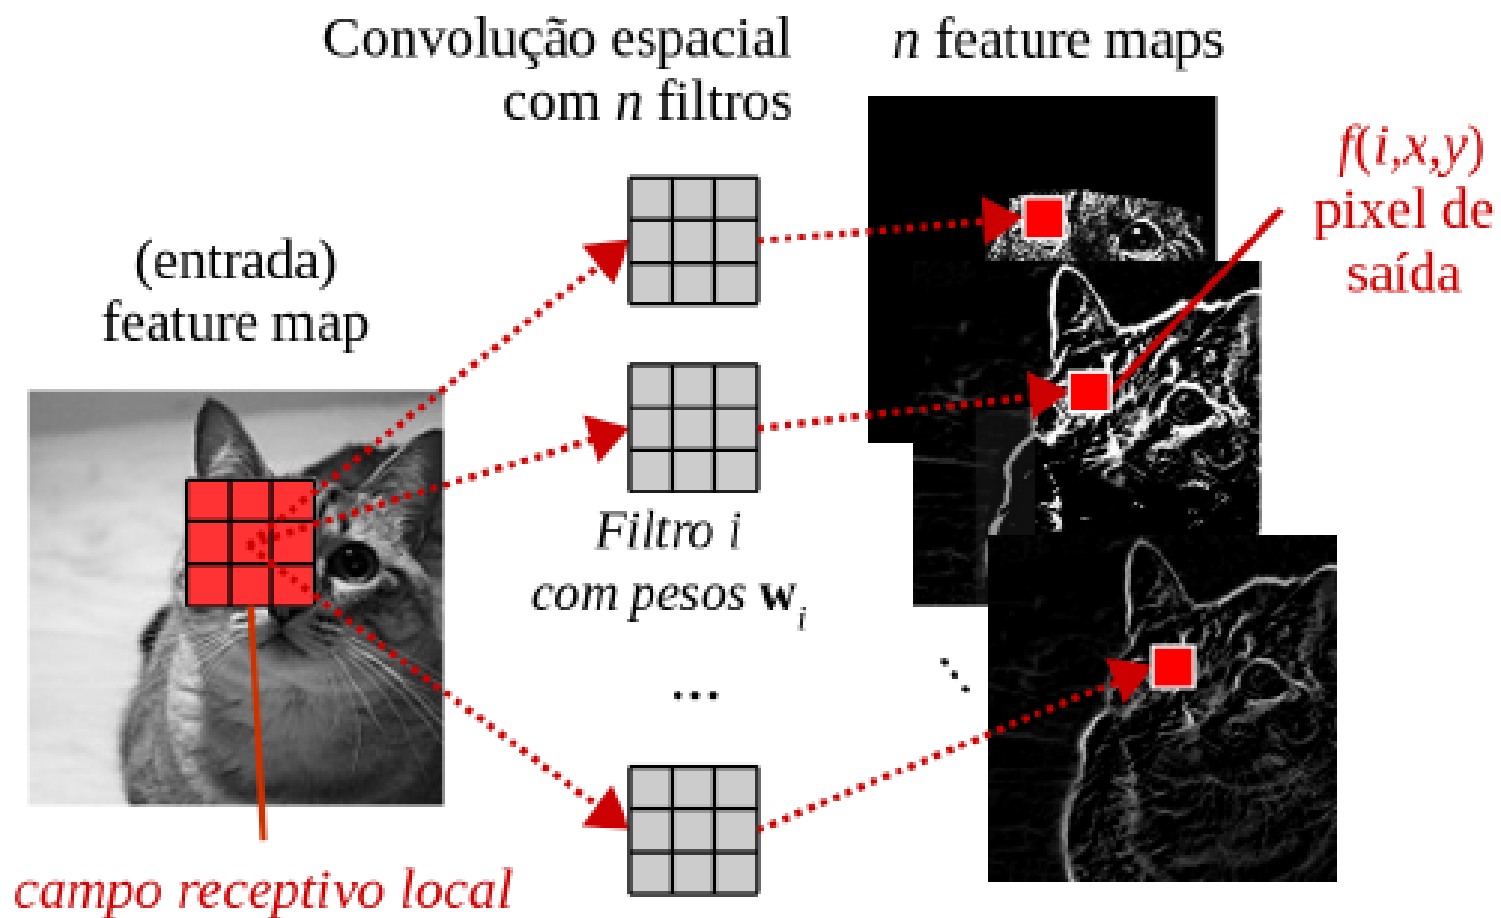
1. Cada neurônio realiza a convolução da entrada e gera um volume (matriz/tensor) de saída  $\rightarrow w \cdot x + b$
2. Mapas de Ativação: são obtidos após a convolução e função de ativação (RELU)

# Camada Convolutiva

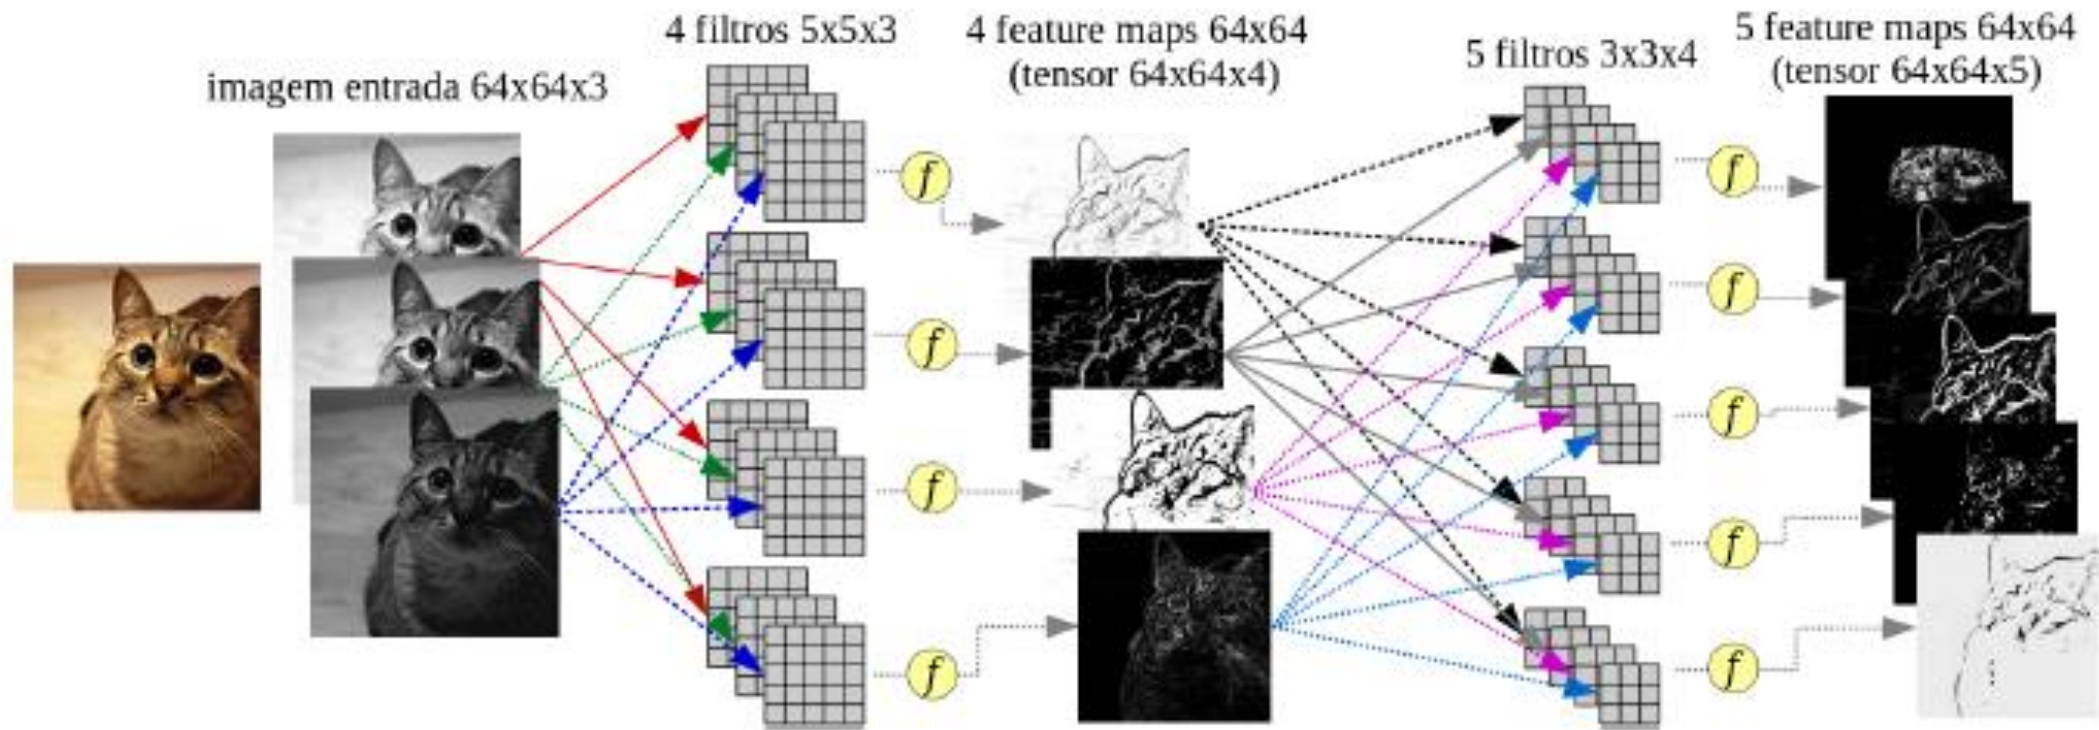
- Feature Maps: Empilhados formam um tensor que será a entrada da próxima camada.



# Camada Convolutiva



# Camada Convolucional




# Camada Convolutacional

A camada convolutacional tem que levar em conta:

- o tamanho da entrada (largura, altura, profundidade)
- o tamanho do filtro
  - a profundidade deve ser igual à da entrada
  - a altura e largura afetam o campo receptivo local
- stride (passo)
  - = 1 : todos os pixels são filtrados pelo neurônio
  - > 1 : - salta um número de pixels em determinada direção, a cada convolução.
    - volume de saída tem tamanho reduzido

# SUBAMOSTRAGEM: POOLING LAYER

## 1- Operação MAX pooling 2x2



Reduzir o tamanho da entrada permite que o filtro opere em regiões maiores da imagem




# SUBAMOSTRAGEM: POOLING LAYER

2 - Operação AVERAGE pooling 2x2



# CAMPO RECEPTIVO

- EMPILHAMENTO DE CAMADAS CONVOLUCIONAIS AUMENTA O CAMPO RECEPTIVO LOCAL NÃO NECESSITANDO MANTER A RESOLUÇÃO DA ENTRADA




- filtro de mesmo tamanho
- imagens progressivamente menores

# GLOBAL POOLING

- Obtém um valor por canal, como se o tamanho de pool fosse igual às dimensões laterais
- Ex. numa entrada com  $40 \times 40 \times 100$ , a saída será 100 dimensões.

# FUNÇÃO BINARY CROSS ENTROPY



## OUTRA FUNÇÃO DE CUSTO


- Usando probabilidade condicional:  
 $h(x) = P(y = 1, x)$   
 $1 - h(x) = P(y = 0, x)$  (pela regra de probabilidade complementar)
- Combinando as 2 equações, obtemos:  
 $P(y, x) = (h(x)^y) * ((1 - h(x))^{(1-y)})$

$$\log(P(y/x)) = \sum (y(i)\log(h(x)) + (1 - y(i))\log((1 - h(x))))$$

# **ARQUITETURAS TÍPICAS DE CNN**


# AlexNet (Krizhevsky, 2012)

- ▶ entrada  $224 \times 224$
- ▶ conv1:  $K = 96$  filters with  $11 \times 11 \times 3$ , stride 4,
- ▶ conv2:  $K = 256$  filters with  $5 \times 5 \times 96$ ,
- ▶ conv3:  $K = 384$  filters with  $3 \times 3 \times 256$ ,
- ▶ conv4:  $K = 384$  filters with  $3 \times 3 \times 384$ ,
- ▶ conv5:  $K = 256$  filters with  $3 \times 3 \times 384$ ,
- ▶ densas1, 2:  $K = 4096$ .




# VGGNet (Simonyan, 2014)

- ▶ entrada  $224 \times 224$ ,
- ▶ filtros: todos  $3 \times 3$ ,
- ▶ conv 1-2:  $K = 64 + \text{maxpool}$
- ▶ conv 3-4:  $K = 128 + \text{maxpool}$
- ▶ conv 5-6-7-8:  $K = 256 + \text{maxpool}$
- ▶ conv 9-10-11-12:  $K = 512 + \text{maxpool}$
- ▶ conv 13-14-15-16:  $K = 512 + \text{maxpool}$
- ▶ densas1, 2:  $K = 4096$



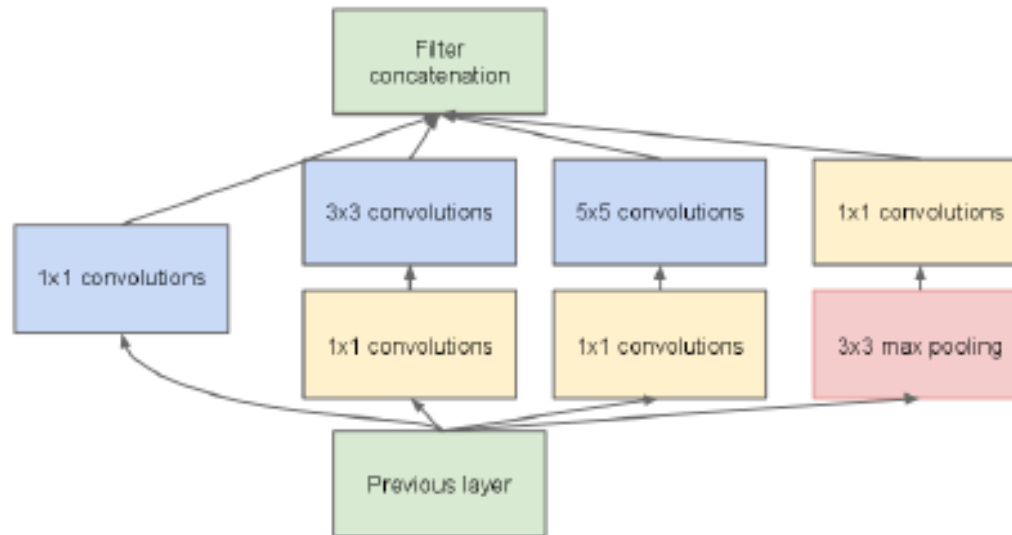
# GoogLeNet / Inception (Szegedy, 2014)

- ▶ 22 layers (v1)
- ▶ *Inception layer* (banco de filtros):
  - ▶ filtros  $1 \times 1$ ,  $3 \times 3$ ,  $5 \times 5$  + max pooling  $3 \times 3$ ;
  - ▶ controla dimensionalidade usando filtros  $1 \times 1$ .
  - ▶ 3 classificadores (não sequenciais)
- ▶ Azul = conv.; Vermelho = pool.; Amarelo = densa+softmax;  
Verde = concatenação.



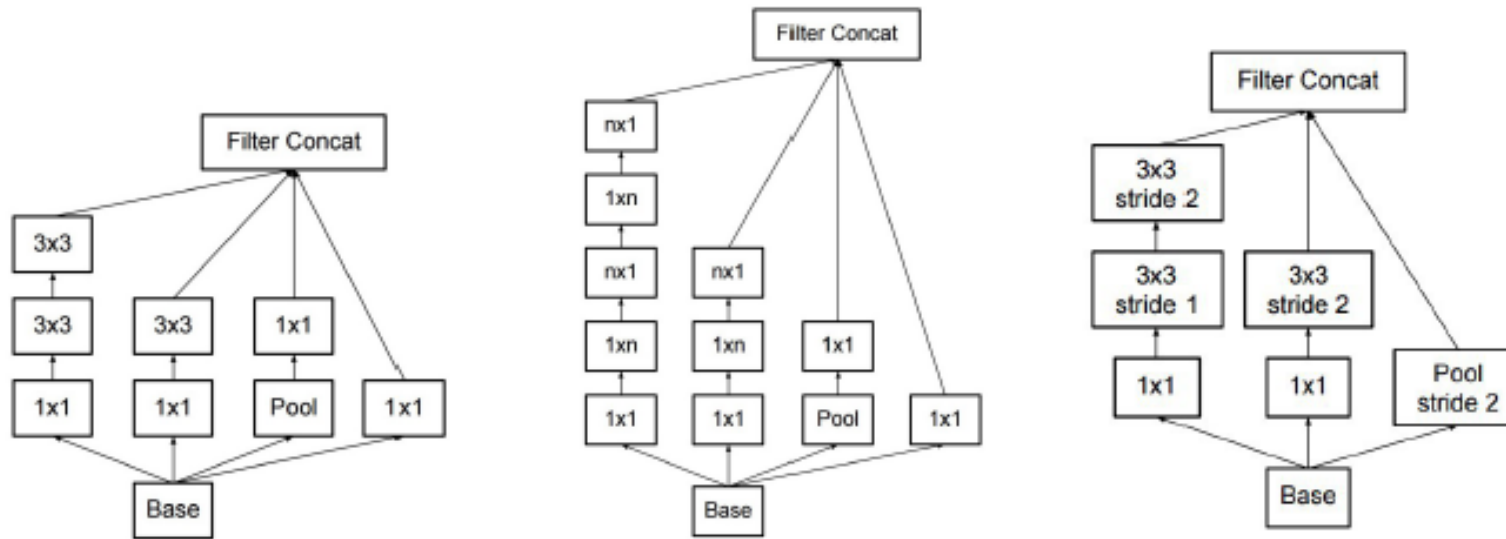


# GoogLeNet: módulo inception v1

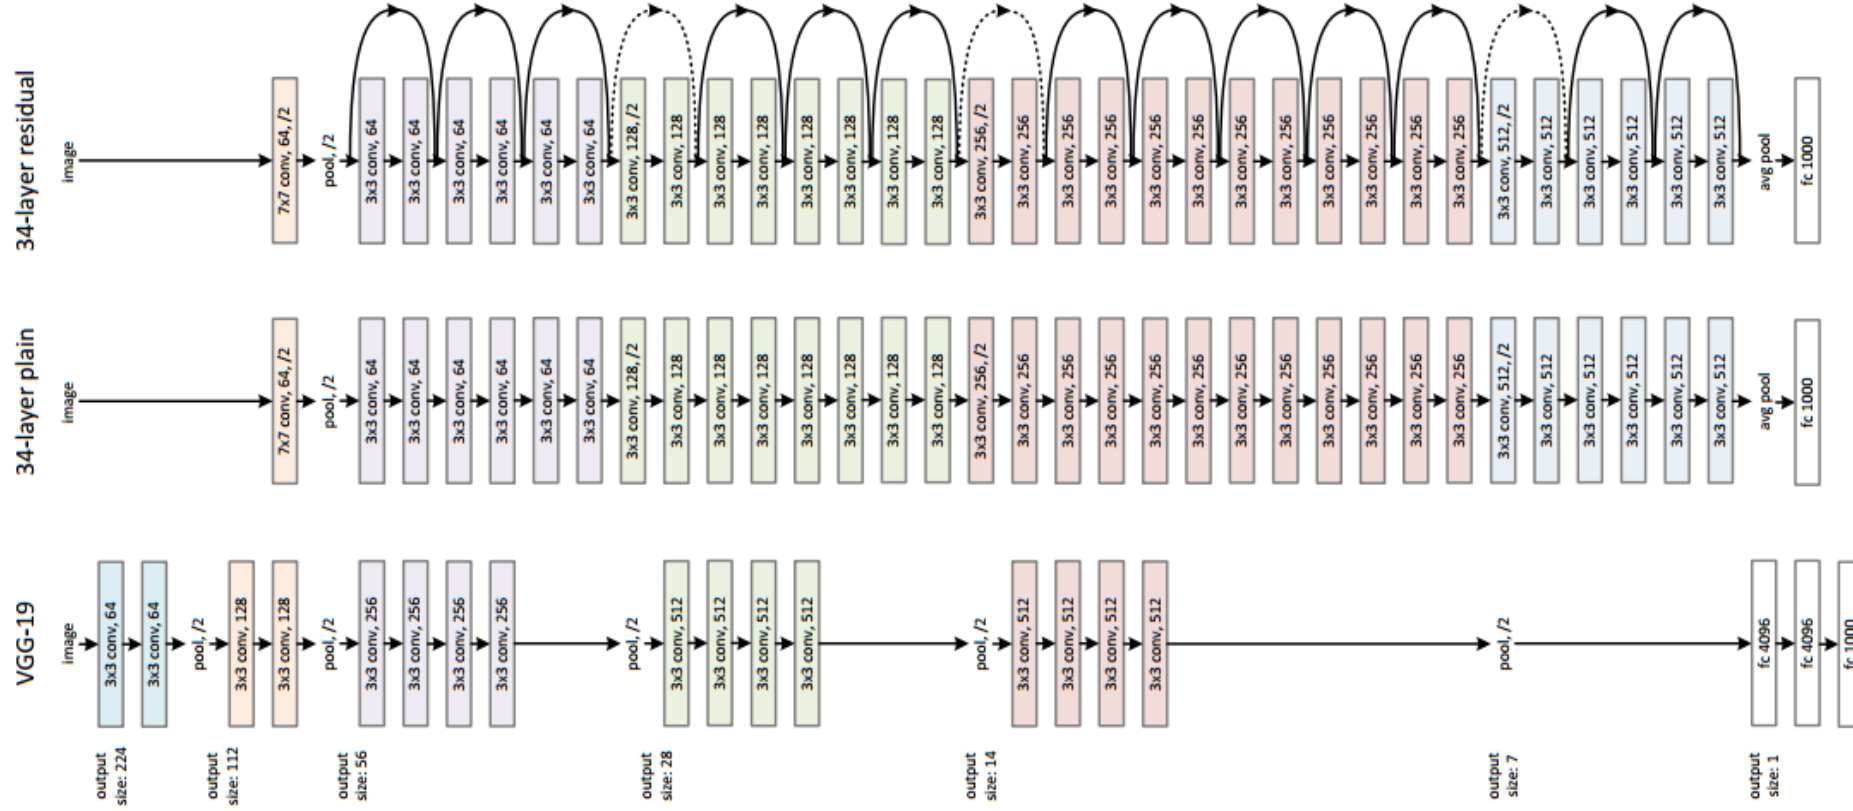


- ▶ filtro  $1 \times 1$  reduz profundidade da entrada
- ▶ concatena ativação de 3 filtros + maxpooling

# Módulos inception (V2 and V3)




# Residual Network (He et al, 2015)



# O gradiente não se comporta igual em todas as camadas

Gradiente medido em cada camada




Agradecimentos a Harini suresh (<http://harinisuresh.com>) pelos gráficos

# Residual Network — ResNet (He et al, 2015)

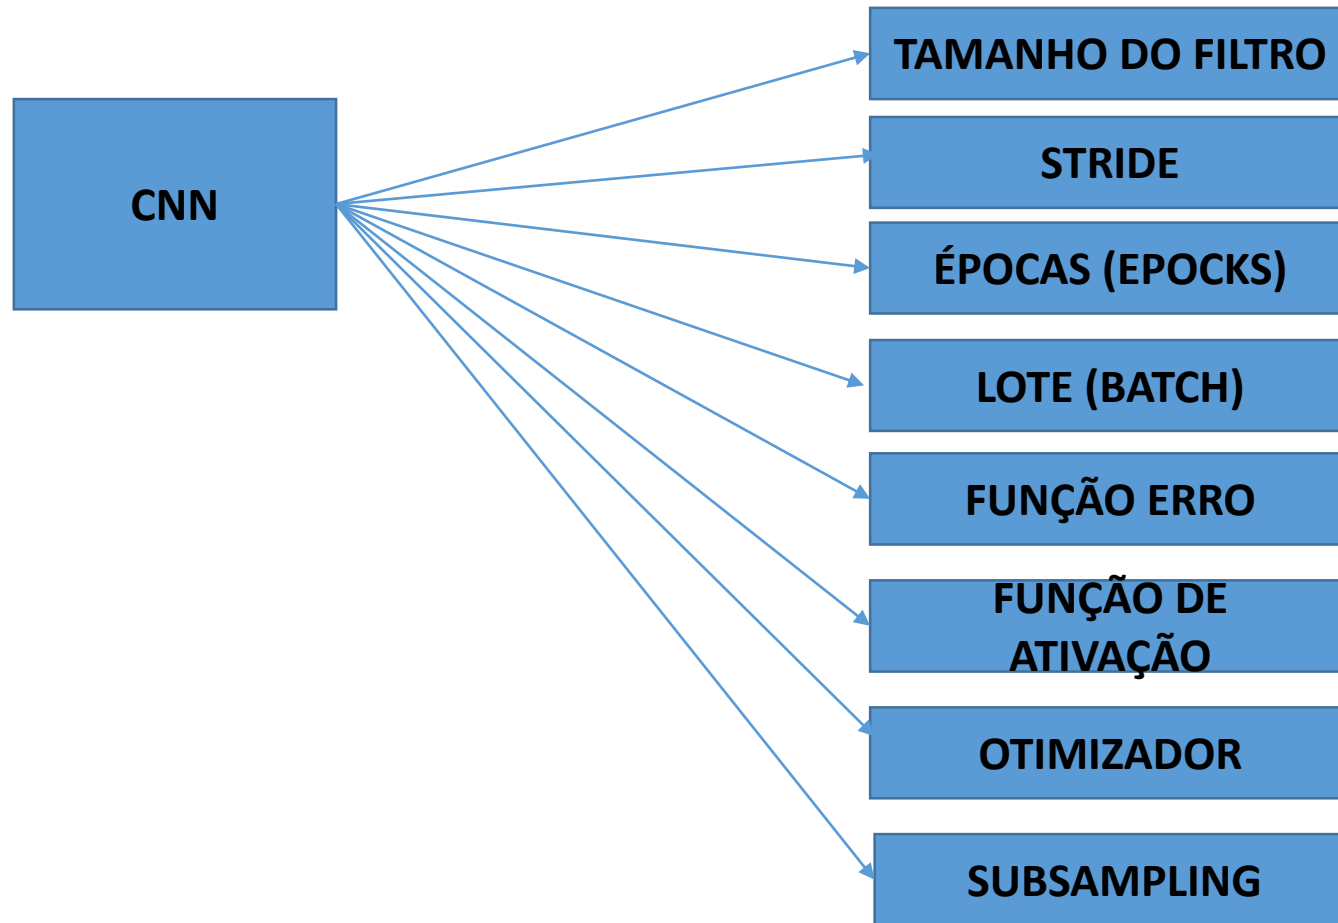
Pular camadas (skip layers) permite:

– empilhar mais camadas (de 34 a  $\sim 1000$ ).

**Residual:** adiciona resultado anterior preservando gradiente.



# IMPLEMENTAÇÃO DA CNN



# **EXEMPLO 2**

**CNN**

**USO DO KERAS**

## **EXEMPLO 3**

## **FUNÇÃO CROSS-ENTROPY**